K03-T1-IF2220-13520006

April 16, 2022

1 Tugas Besar IF2220 Probabilitas dan Statistika

1.1 Penarikan Kesimpulan dan Pengujian Hipotesis

Oleh:
- 13520006 - Vionie Novencia Thanggestyo - 13520069 - Kent Liusudarso

1.1.1 Enam Langkah Testing

1. Tentukan Hipotesis nol ($H_0 : \theta = \theta_0$), dimana θ bisa berupa μ, σ^2, p, atau data lain berdistribusi tertentu (normal, binomial, dsc.).
2. Pilih hipotesis alternatif H1 salah dari dari $\theta > \theta_0$, $\theta < \theta_0$, atau $\theta \neq \theta_0$.
3. Tentukan tingkat signifikan α.
4. Tentukan uji statistik yang sesuai dan tentukan daerah kritis.
5. Hitung nilai uji statistik dari data sample. Hitung *p-value* sesuai dengan uji statistik yang digunakan.
6. Ambil keputusan dengan TOLAK H_0 jika nilai uji terletak di daerah kritis atau dengan tes signifikan, TOLAK H_0 jika *p-value* lebih kecil dibanding tingkat signifikansi α yang diinginkan.

1.1.2 Import Modules & Data

[ ]:
```
import pandas as pd
import matplotlib.pyplot as plt
import scipy.stats as stats
import numpy as np
import seaborn as sns

coloumn_names = ['id', 'pH', 'Hardness', 'Solids', 'Chloramines', 'Sulfate',␣
 ↪'Conductivity', 'OrganicCarbon', 'Trihalomethanes', 'Turbidity',␣
 ↪'Potability']
df = pd.read_csv('water_potability.csv', names=coloumn_names)
df
```

[ ]:

	id	pH	Hardness	Solids	Chloramines	Sulfate	\
0	1	8.316766	214.373394	22018.417441	8.059332	356.886136	
1	2	9.092223	181.101509	17978.986339	6.546600	310.135738	
2	3	5.584087	188.313324	28748.687739	7.544869	326.678363	

```
3        4  10.223862  248.071735  28749.716544     7.513408  393.663396
4        5   8.635849  203.361523  13672.091764     4.563009  303.309771
…      …         …          …            …           …         …
2005  2006   8.197353  203.105091  27701.794055     6.472914  328.886838
2006  2007   8.989900  215.047358  15921.412018     6.297312  312.931022
2007  2008   6.702547  207.321086  17246.920347     7.708117  304.510230
2008  2009  11.491011   94.812545  37188.826022     9.263166  258.930600
2009  2010   6.069616  186.659040  26138.780191     7.747547  345.700257

      Conductivity  OrganicCarbon  Trihalomethanes  Turbidity  Potability
0       363.266516      18.436524       100.341674   4.628771           0
1       398.410813      11.558279        31.997993   4.075075           0
2       280.467916       8.399735        54.917862   2.559708           0
3       283.651634      13.789695        84.603556   2.672989           0
4       474.607645      12.363817        62.798309   4.401425           0
…              …            …               …        …         …
2005    444.612724      14.250875        62.906205   3.361833           1
2006    390.410231       9.899115        55.069304   4.613843           1
2007    329.266002      16.217303        28.878601   3.442983           1
2008    439.893618      16.172755        41.558501   4.369264           1
2009    415.886955      12.067620        60.419921   3.669712           1

[2010 rows x 11 columns]
```

1.1.3 Soal 1

Menulis deskripsi statistika (*Descriptive Statistics*) dari semua kolom pada data yang bersifat numerik, terdiri dari mean, median, modus, standar deviasi, variansi, range, nilai minimum, maksimum, kuartil, IQR, skewness dan kurtosis. Boleh juga ditambahkan deskripsi lain.

[ ]:
```
df1 = df.describe(include=[np.number])
df1.loc['variansi'] = df.var()
df1.loc['range'] = df.max() - df.min()
df1.loc['IQR'] = df.quantile(0.75) - df.quantile(0.25)
df1.loc['skewness'] = df.skew()
df1.loc['kurtosis'] = df.kurt()
modus = []
for coloumn in df1:
    if (df[coloumn].mode().count() == len(df)):
        modus.append('None')
    else:
        modus.append(df[coloumn].mode()[0])
df1.loc['modus'] = modus
df1
```

[ ]:
```
                id         pH     Hardness           Solids Chloramines  \
count        2010.0     2010.0       2010.0           2010.0      2010.0
```

mean	1005.5	7.087193	195.969209	21904.673439	7.134322
std	580.38134	1.572803	32.643166	8625.397911	1.585214
min	1.0	0.227499	73.492234	320.942611	1.390871
25%	503.25	6.090785	176.740657	15614.412962	6.138326
50%	1005.5	7.02949	197.203525	20926.882155	7.142014
75%	1507.75	8.053006	216.447589	27170.534649	8.109933
max	2010.0	14.0	317.338124	56488.672413	13.127
variansi	336842.5	2.473709	1065.576277	74397489.126371	2.512904
range	2009.0	13.772501	243.84589	56167.729801	11.736129
IQR	1004.5	1.962221	39.706932	11556.121687	1.971607
skewness	0.0	0.048535	-0.085321	0.591011	0.013003
kurtosis	-1.2	0.626904	0.52548	0.33732	0.549782
modus	None	None	None	None	None

	Sulfate	Conductivity	OrganicCarbon	Trihalomethanes	Turbidity	\
count	2010.0	2010.0	2010.0	2010.0	2010.0	
mean	333.211376	426.476708	14.35794	66.400717	3.969497	
std	41.211111	80.701872	3.32577	16.081109	0.780471	
min	129.0	201.619737	2.2	8.577013	1.45	
25%	307.626986	366.619219	12.12253	55.949993	3.442882	
50%	332.214113	423.438372	14.323286	66.482041	3.967374	
75%	359.268147	482.209772	16.683562	77.294613	4.514663	
max	481.030642	753.34262	27.006707	124.0	6.494749	
variansi	1698.355672	6512.792113	11.060746	258.602066	0.609135	
range	352.030642	551.722883	24.806707	115.422987	5.044749	
IQR	51.641161	115.590553	4.561031	21.34462	1.071781	
skewness	-0.045728	0.268012	-0.02022	-0.051383	-0.032266	
kurtosis	0.786854	-0.237206	0.031018	0.223017	-0.049831	
modus	None	None	None	None	None	

	Potability
count	2010.000000
mean	0.402985
std	0.490620
min	0.000000
25%	0.000000
50%	0.000000
75%	1.000000
max	1.000000
variansi	0.240708
range	1.000000
IQR	1.000000
skewness	0.395873
kurtosis	-1.845122
modus	0.000000

1.1.4 Soal 2

Membuat Visualisasi plot distribusi, dalam bentuk histogram dan boxplot untuk setiap kolom numerik. Berikan uraian penjelasan kondisi setiap kolom berdasarkan kedua plot tersebut.

pH histogram pH di bawah ini menunjukkan data bersifat skew normal dan lepto kurtik. Data juga memiliki pencilan atas dan pencilan bawah seperti yang ditunjukkan pada boxplot

[ ]:
```
sns.histplot(df["pH"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='pH', ylabel='Count'>
```

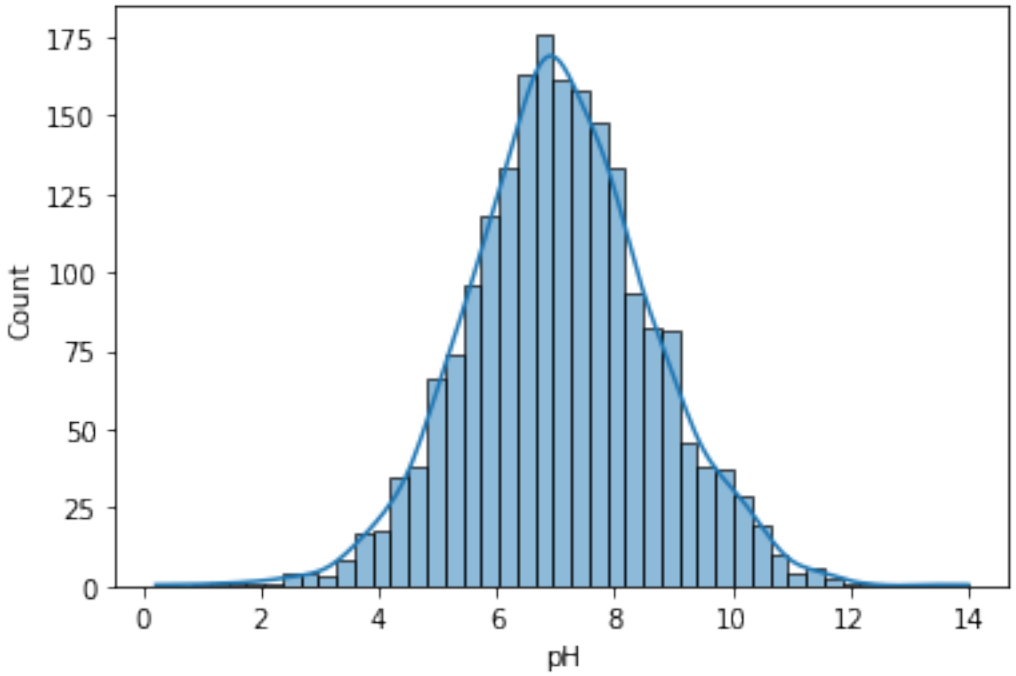

[ ]:
```
df.boxplot("pH")
```

[ ]:
```
<AxesSubplot:>
```

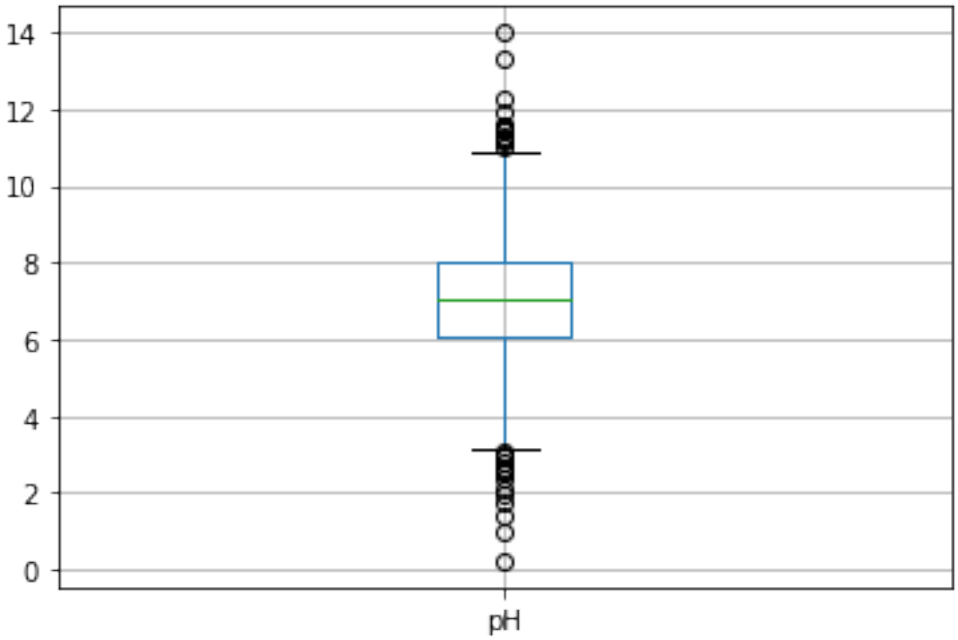

Hardness histogram Hardness di bawah ini menunjukkan data bersifat skew normal dan lepto kurtik. Data juga memiliki pencilan atas dan pencilan bawah seperti yang ditunjukkan pada boxplot

[ ]:
```
sns.histplot(df["Hardness"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Hardness', ylabel='Count'>
```

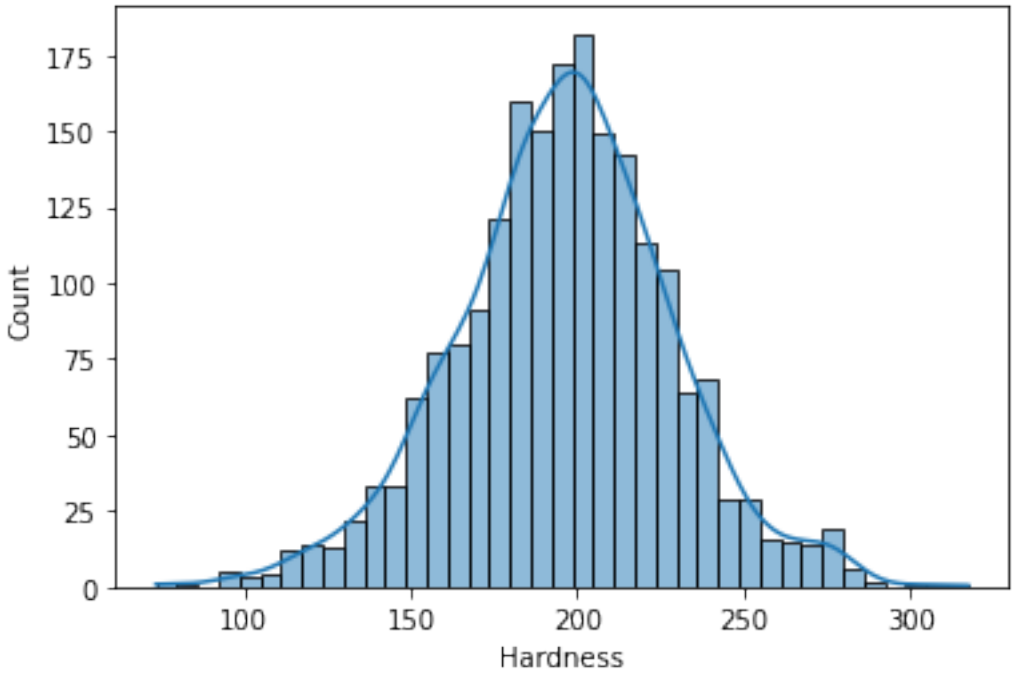

[ ]:
```
df.boxplot("Hardness")
```

[ ]: <AxesSubplot:>

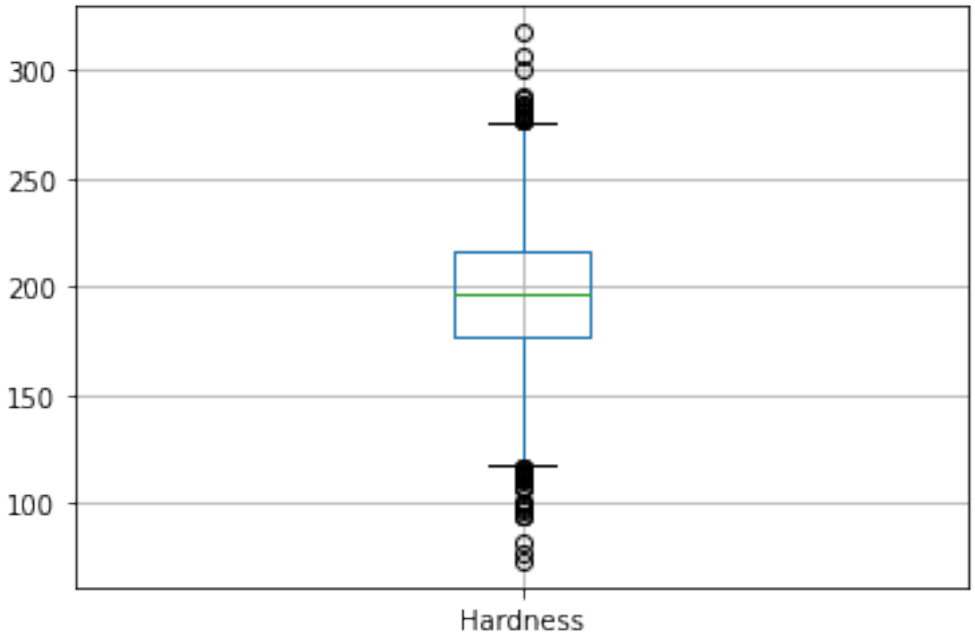

Solids histogram Solids di bawah ini menunjukkan data bersifat skew positif dan meso kurtik. Data juga memiliki pencilan atas seperti yang ditunjukkan pada boxplot

[ ]:
```
sns.histplot(df["Solids"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Solids', ylabel='Count'>
```

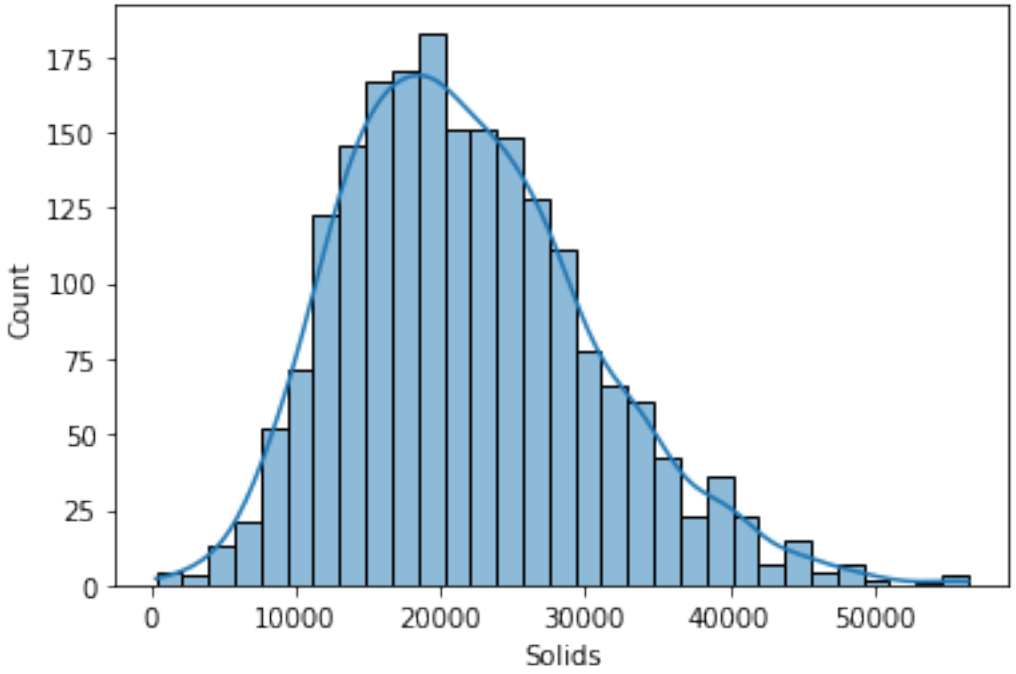

[ ]:
```
df.boxplot("Solids")
```

[ ]:
```
<AxesSubplot:>
```

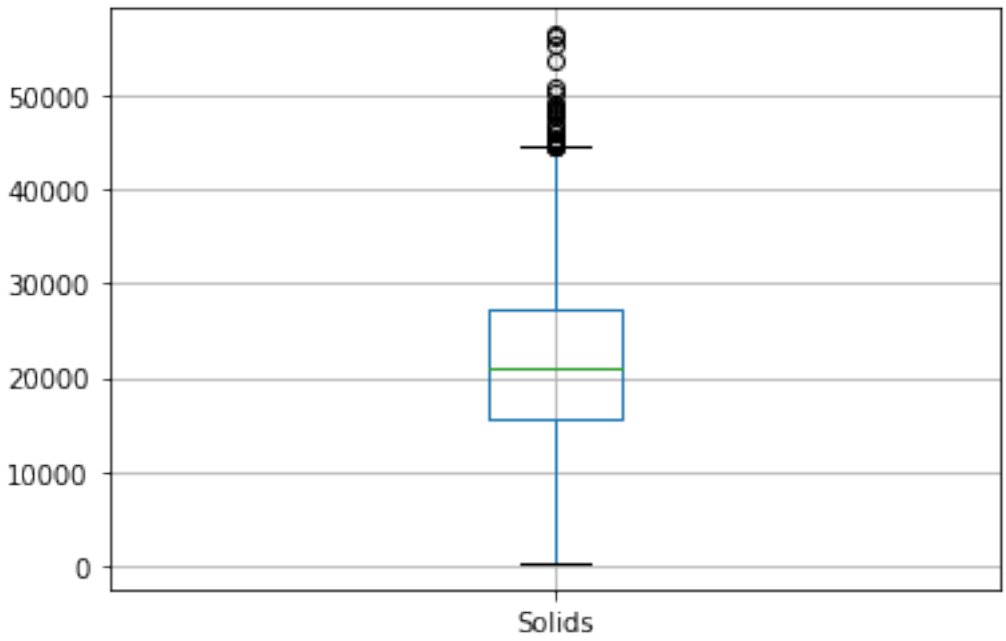

Chloramines histogram Chloramines di bawah ini menunjukkan data bersifat skew normal dan lepto kurtik. Data juga memiliki pencilan atas dan pencialn bawah seperti yang ditunjukkan pada boxplot

[ ]:
```
sns.histplot(df["Chloramines"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Chloramines', ylabel='Count'>
```

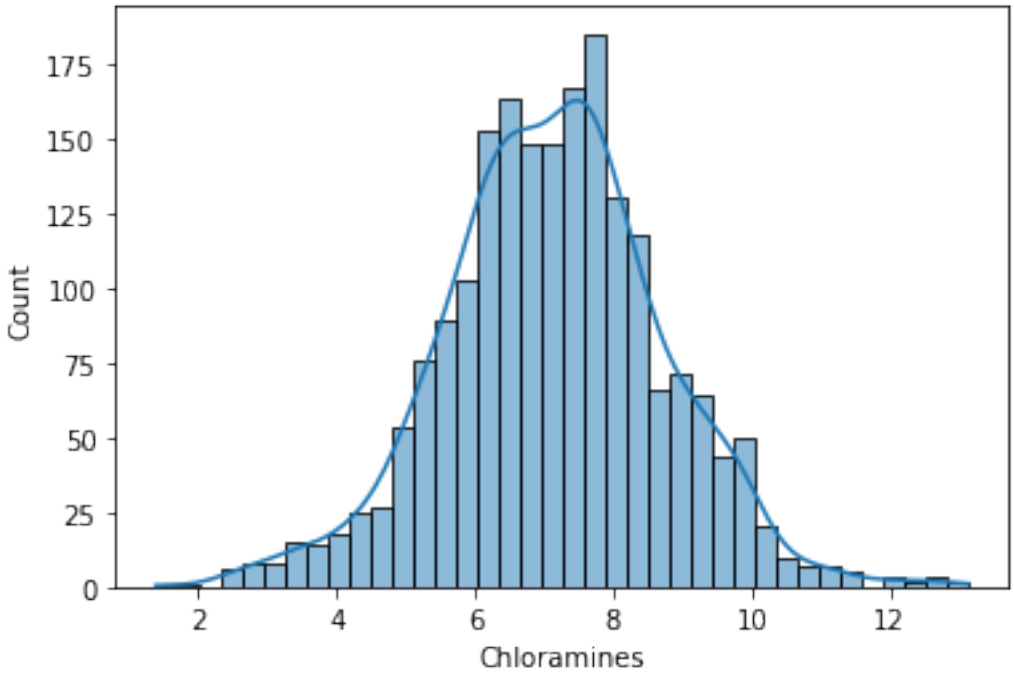

[ ]:
```
df.boxplot("Chloramines")
```

[ ]: <AxesSubplot:>

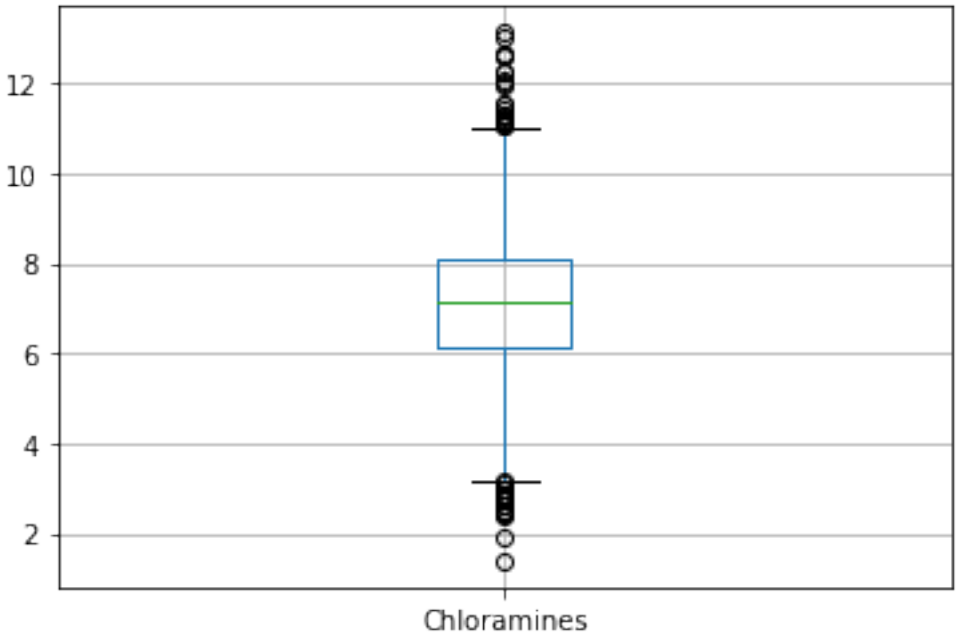

Sulfate histogram Sulfate di bawah ini menunjukkan data bersifat skew noraml dan lepto kurtik. Data juga memiliki pencilan atas dan pencilan bawah seperti yang ditunjukkan pada boxplot

[ ]:
```
sns.histplot(df["Sulfate"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate', ylabel='Count'>
```

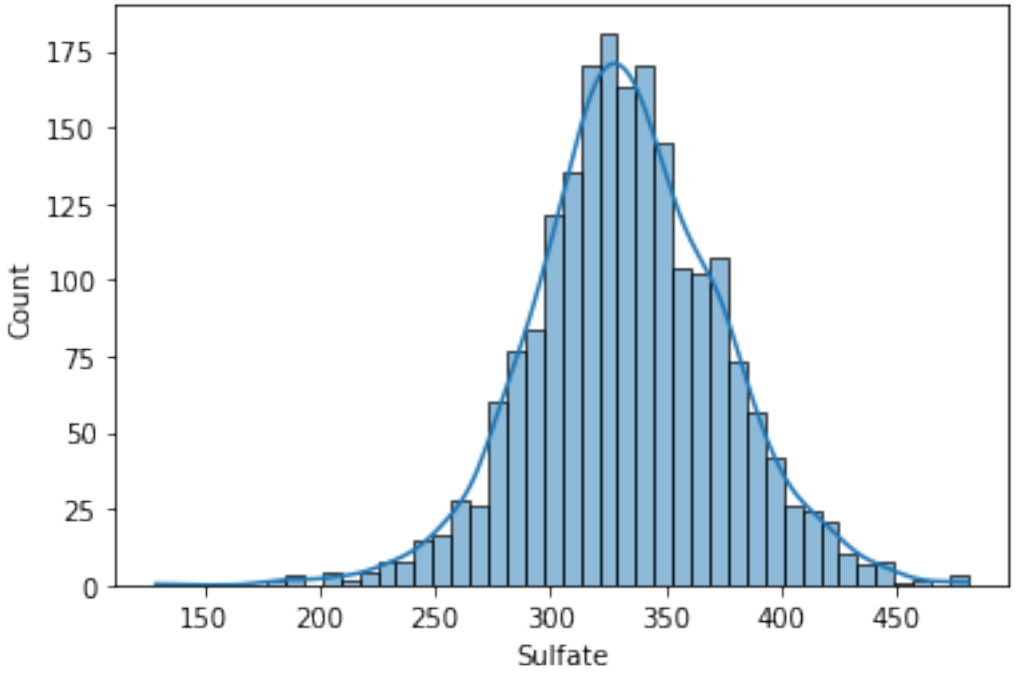

[ ]:
```
df.boxplot("Sulfate")
```

[ ]:
```
<AxesSubplot:>
```

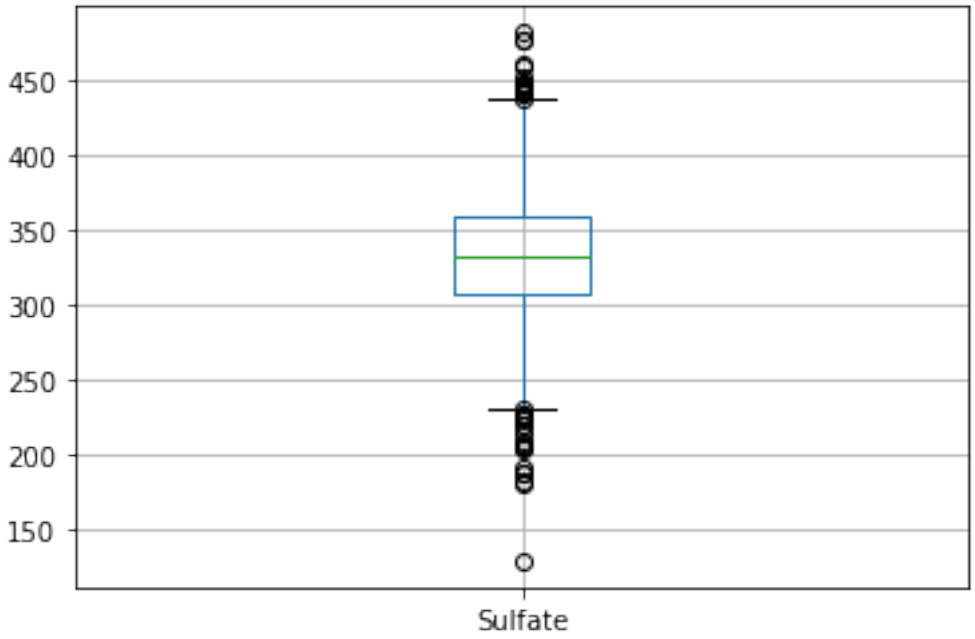

Conductivity histogram Conductivity di bawah ini menunjukkan data bersifat skew positif dan meso kurtik. Data juga memiliki pencilan atas seperti yang ditunjukkan pada boxplot

[ ]:
```
sns.histplot(df["Conductivity"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Conductivity', ylabel='Count'>
```

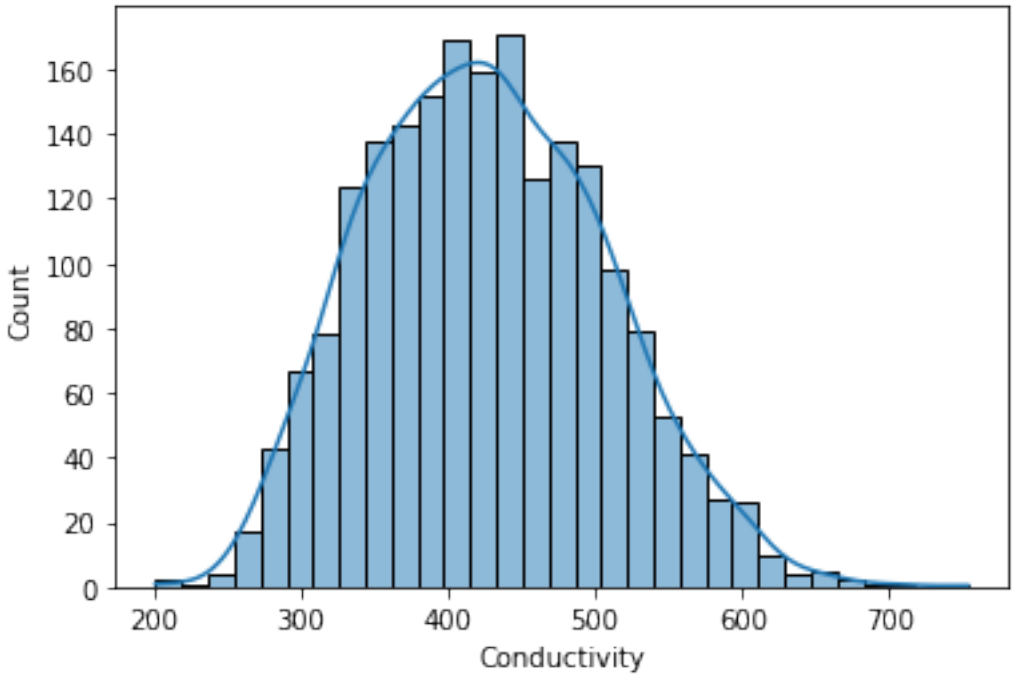

[ ]:
```
df.boxplot("Conductivity")
```

[ ]: <AxesSubplot:>

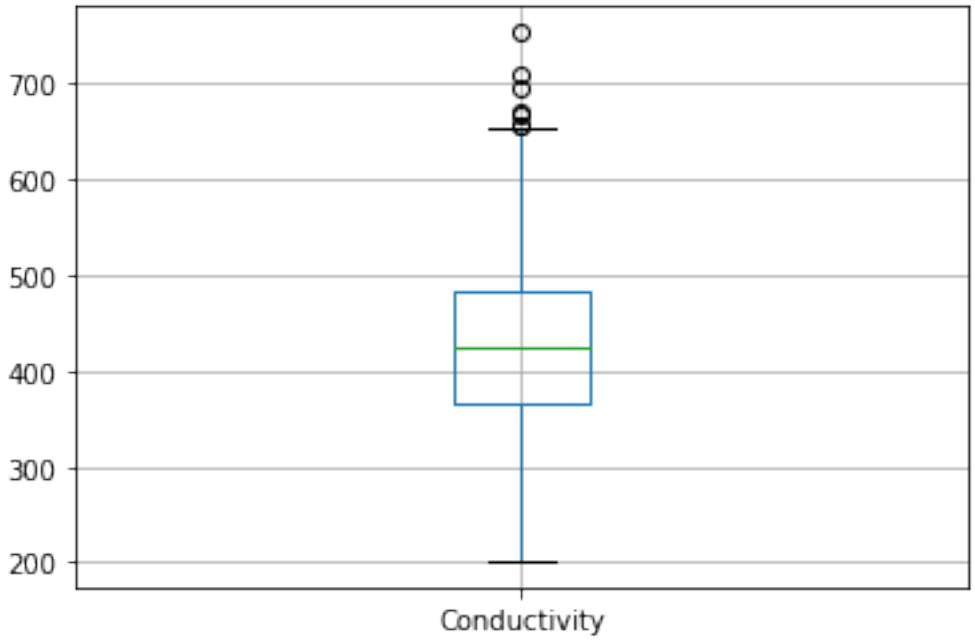

OrganicCarbon histogram OrganicCarbon di bawah ini menunjukkan data bersifat skew positif dan plati kurtik. Data juga memiliki pencilan atas seperti yang ditunjukkan pada boxplot

[ ]:
```
sns.histplot(df["OrganicCarbon"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='OrganicCarbon', ylabel='Count'>
```

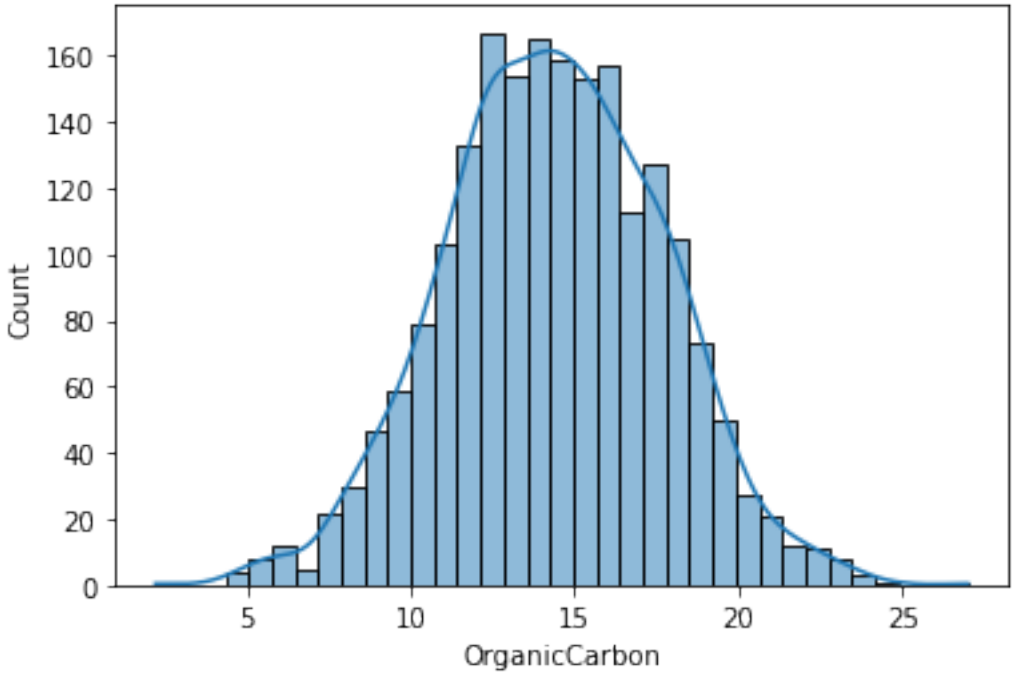

[ ]:
```
df.boxplot("OrganicCarbon")
```

[ ]:
```
<AxesSubplot:>
```

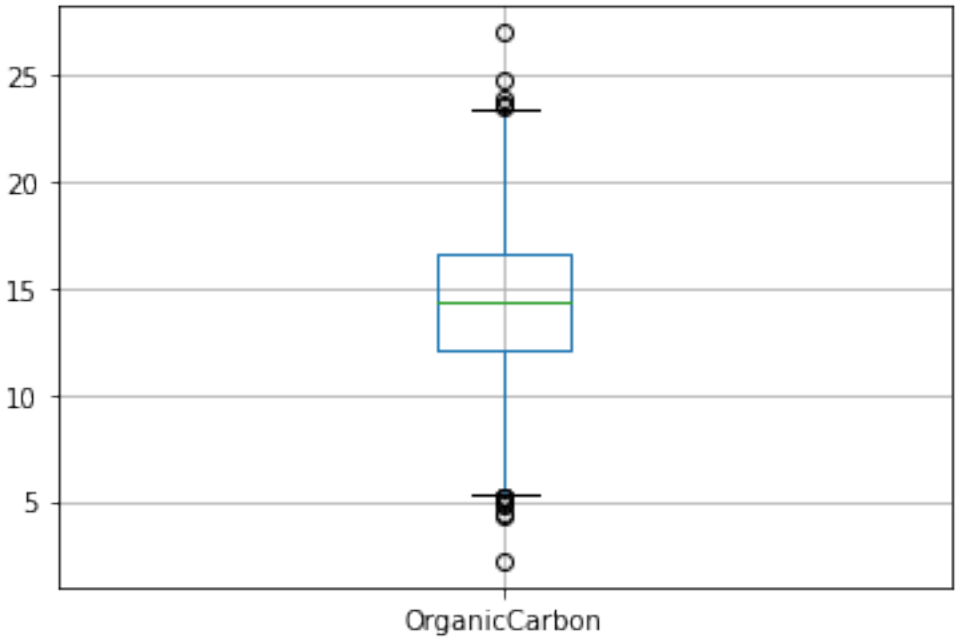

Trihalomethanes histogram Trihalomethanes di bawah ini menunjukkan data bersifat skew negatif dan meso kurtik. Data juga memiliki pencilan atas seperti yang ditunjukkan pada boxplot

[ ]:
```
sns.histplot(df["Trihalomethanes"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Trihalomethanes', ylabel='Count'>
```

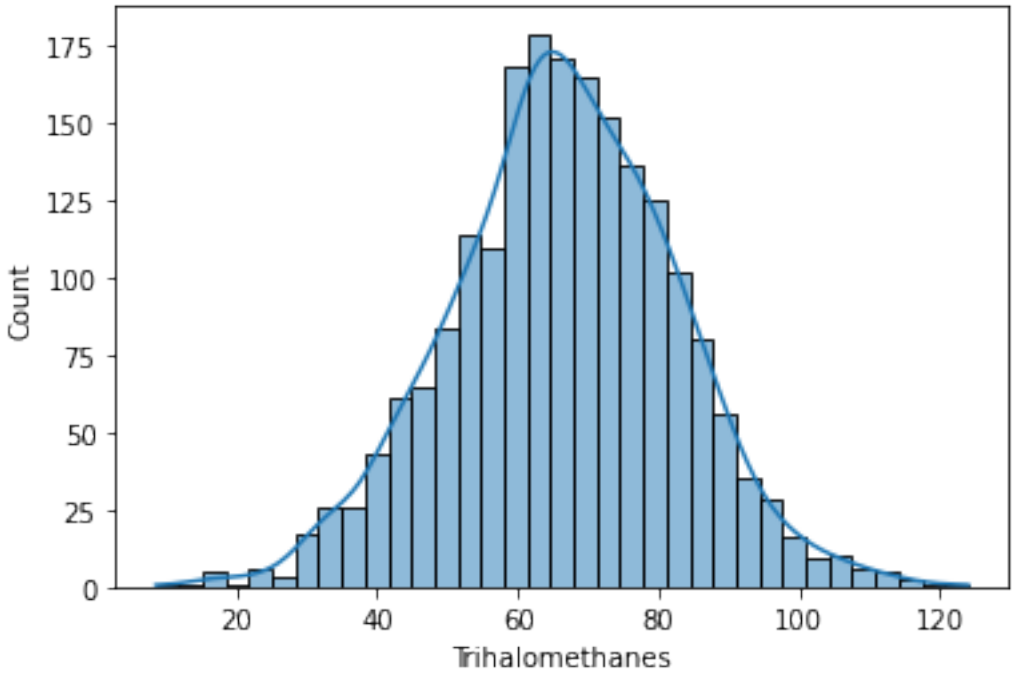

[ ]:
```
df.boxplot("Trihalomethanes")
```

[ ]: <AxesSubplot:>

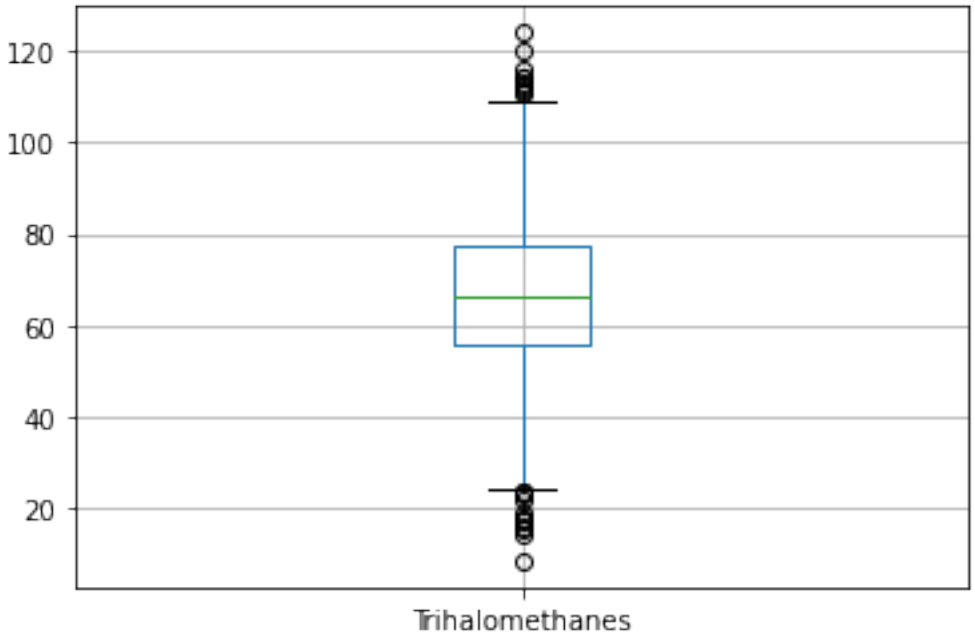

Turbidity histogram Turbidity di bawah ini menunjukkan data bersifat skew normal dan meso kurtik. Data juga memiliki pencilan atas seperti yang ditunjukkan pada boxplot

[ ]:
```
sns.histplot(df["Turbidity"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Turbidity', ylabel='Count'>
```

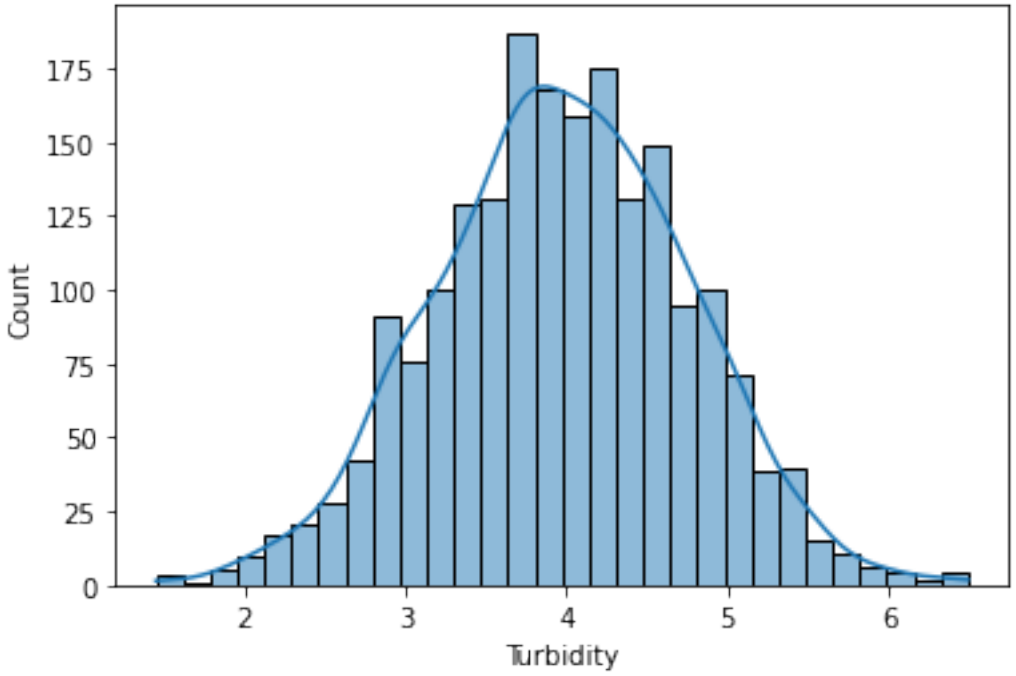

[ ]:
```
df.boxplot("Turbidity")
```

[ ]:
```
<AxesSubplot:>
```

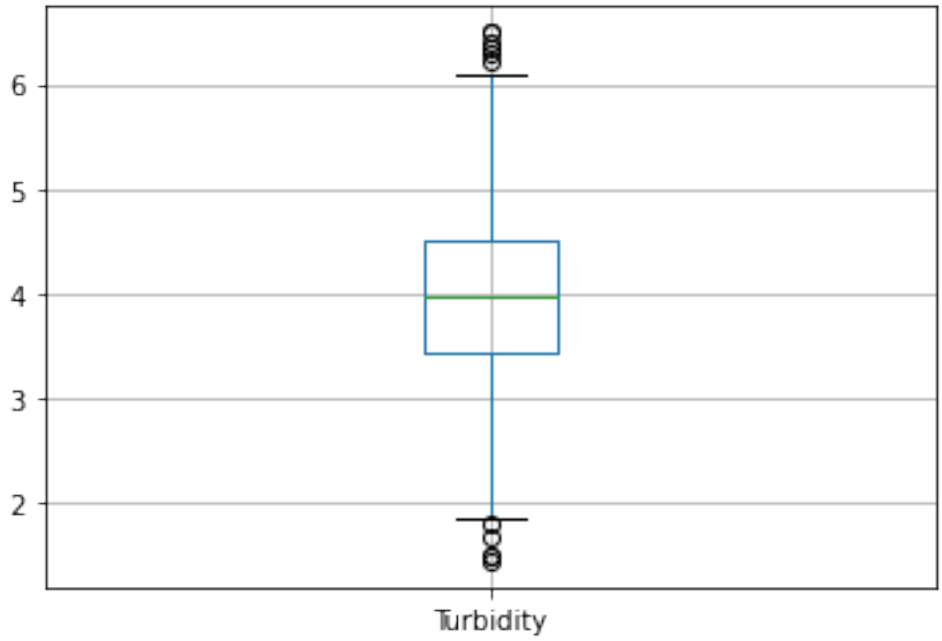

1.1.5 Soal 3

Menentukan setiap kolom numerik berdistribusi normal atau tidak. Gunakan normality test yang dikaitkan dengan histogram plot.

D'Agostino's K-squared D'Agostino's K-squared test menentukan apakah sebuah kolom berdistribusi normal atau tidak menurut skewness dan kurtosisnya. Jika hasil tes merupakan distribusi normal, maka pada histogram akan terlihat bell curve.

pH

[ ]:
```
sns.histplot(df["pH"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='pH', ylabel='Count'>
```

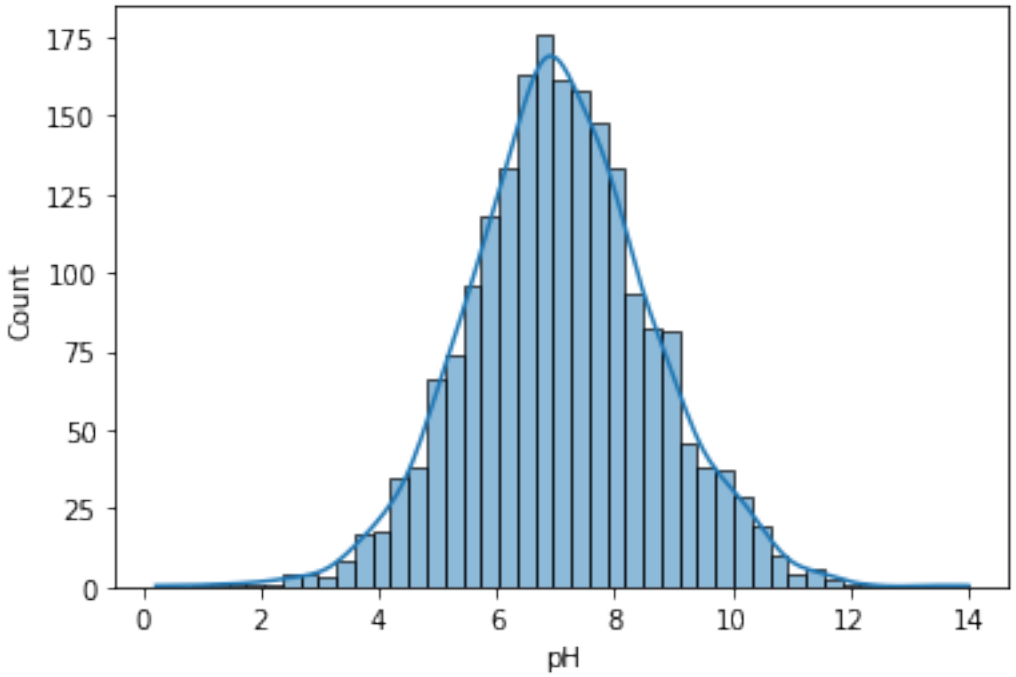

[ ]:
```
stat, p = stats.normaltest(df["pH"])
print('stat=%.3f, p=%.3f' % (stat, p))
if p > 0.05:
    print('Berdistribusi Normal')
else:
    print('Tidak Berdistribusi Normal')
```

```
stat=21.076, p=0.000
Tidak Berdistribusi Normal
```

Hardness

[ ]:
```
sns.histplot(df["Hardness"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Hardness', ylabel='Count'>
```

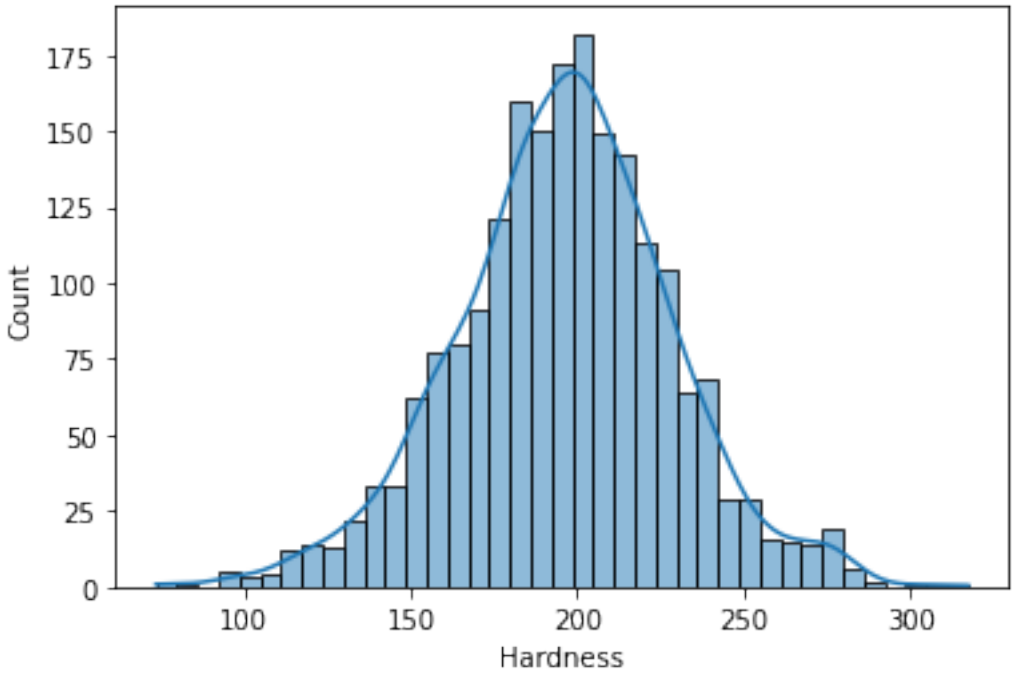

[ ]:
```
stat, p = stats.normaltest(df["pH"])
print('stat=%.3f, p=%.3f' % (stat, p))
if p > 0.05:
    print('Berdistribusi Normal')
else:
    print('Tidak Berdistribusi Normal')
```

```
stat=21.076, p=0.000
Tidak Berdistribusi Normal
```

Solids

[ ]:
```
sns.histplot(df["Solids"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Solids', ylabel='Count'>
```

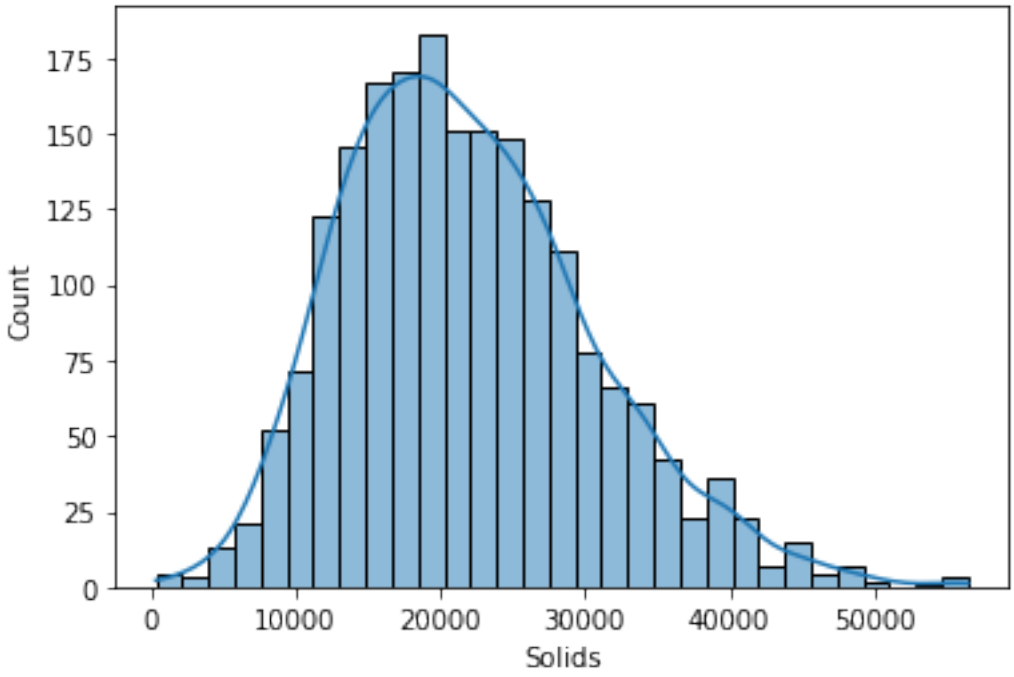

[ ]:
```
stat, p = stats.normaltest(df["Solids"])
print('stat=%.3f, p=%.3f' % (stat, p))
if p > 0.05:
    print('Berdistribusi Normal')
else:
    print('Tidak Berdistribusi Normal')
```

```
stat=109.060, p=0.000
Tidak Berdistribusi Normal
```

Chloramines

[ ]:
```
sns.histplot(df["Chloramines"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Chloramines', ylabel='Count'>
```

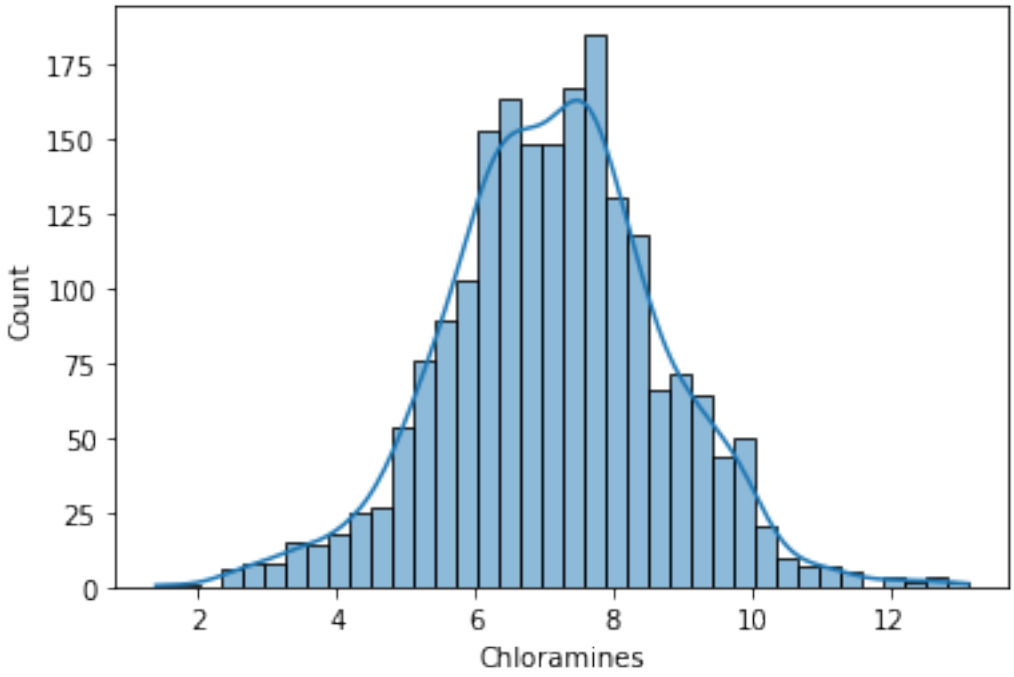

[ ]:
```
stat, p = stats.normaltest(df["Chloramines"])
print('stat=%.3f, p=%.3f' % (stat, p))
if p > 0.05:
    print('Berdistribusi Normal')
else:
    print('Tidak Berdistribusi Normal')
```

```
stat=16.584, p=0.000
Tidak Berdistribusi Normal
```

Sulfate

[ ]:
```
sns.histplot(df["Sulfate"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate', ylabel='Count'>
```

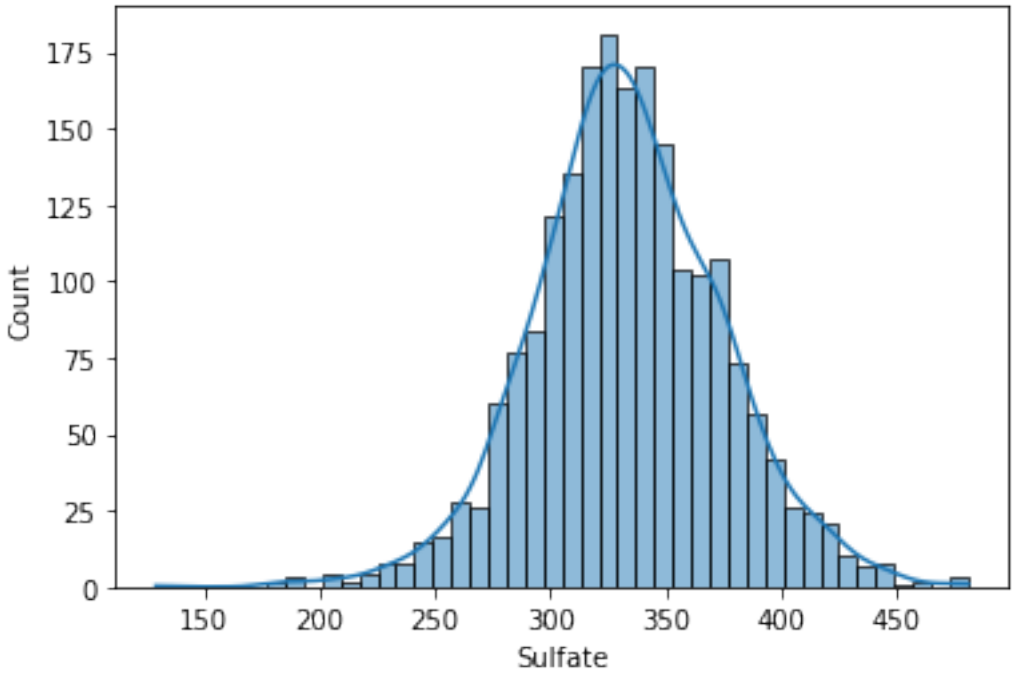

[ ]:
```
stat, p = stats.normaltest(df["Sulfate"])
print('stat=%.3f, p=%.3f' % (stat, p))
if p > 0.05:
    print('Berdistribusi Normal')
else:
    print('Tidak Berdistribusi Normal')
```

```
stat=29.261, p=0.000
Tidak Berdistribusi Normal
```

Conductivity

[ ]:
```
sns.histplot(df["Conductivity"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Conductivity', ylabel='Count'>
```

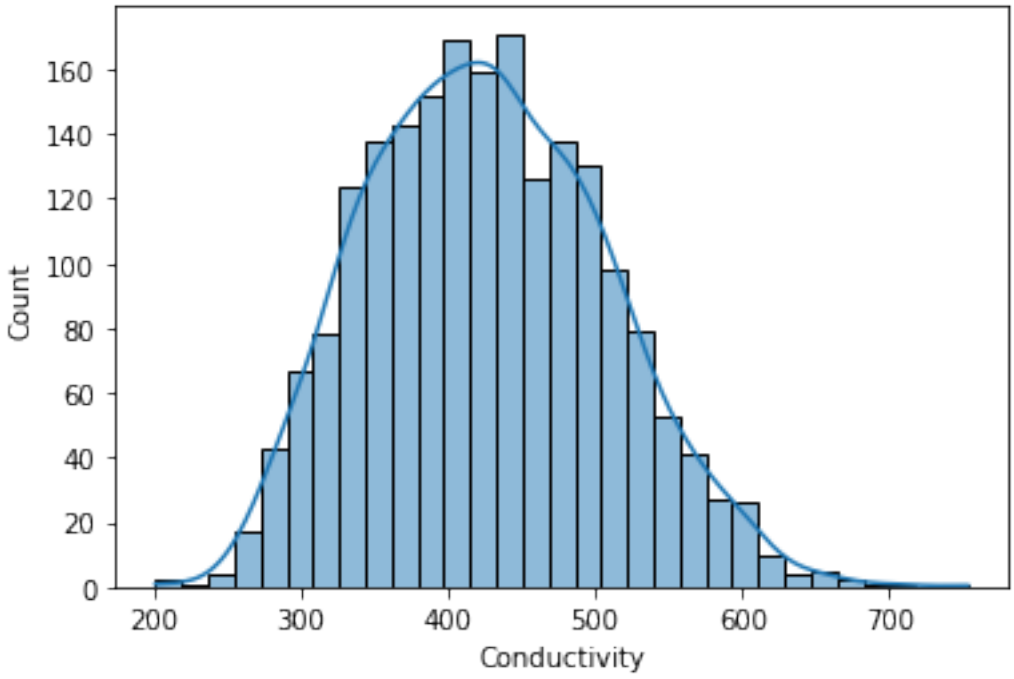

[ ]:
```
stat, p = stats.normaltest(df["Conductivity"])
print('stat=%.3f, p=%.3f' % (stat, p))
if p > 0.05:
    print('Berdistribusi Normal')
else:
    print('Tidak Berdistribusi Normal')
```

```
stat=29.277, p=0.000
Tidak Berdistribusi Normal
```

OrganicCarbon

[ ]:
```
sns.histplot(df["OrganicCarbon"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='OrganicCarbon', ylabel='Count'>
```

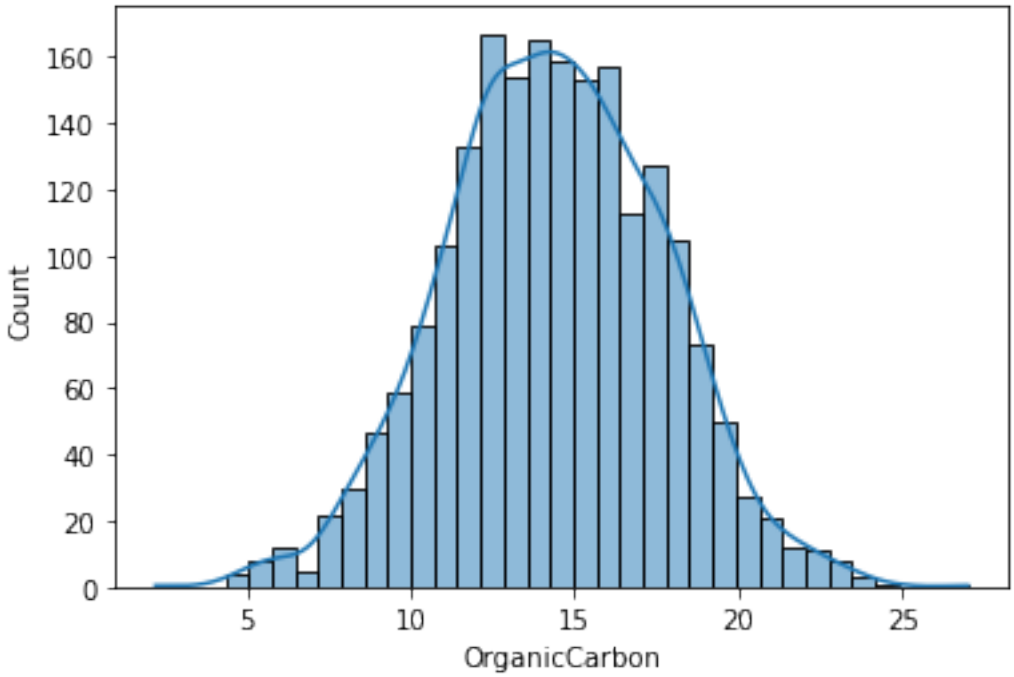

[ ]:
```
stat, p = stats.normaltest(df["OrganicCarbon"])
print('stat=%.3f, p=%.3f' % (stat, p))
if p > 0.05:
    print('Berdistribusi Normal')
else:
    print('Tidak Berdistribusi Normal')
```

```
stat=0.250, p=0.883
Berdistribusi Normal
```

Trihalomethanes

[ ]:
```
sns.histplot(df["Trihalomethanes"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Trihalomethanes', ylabel='Count'>
```

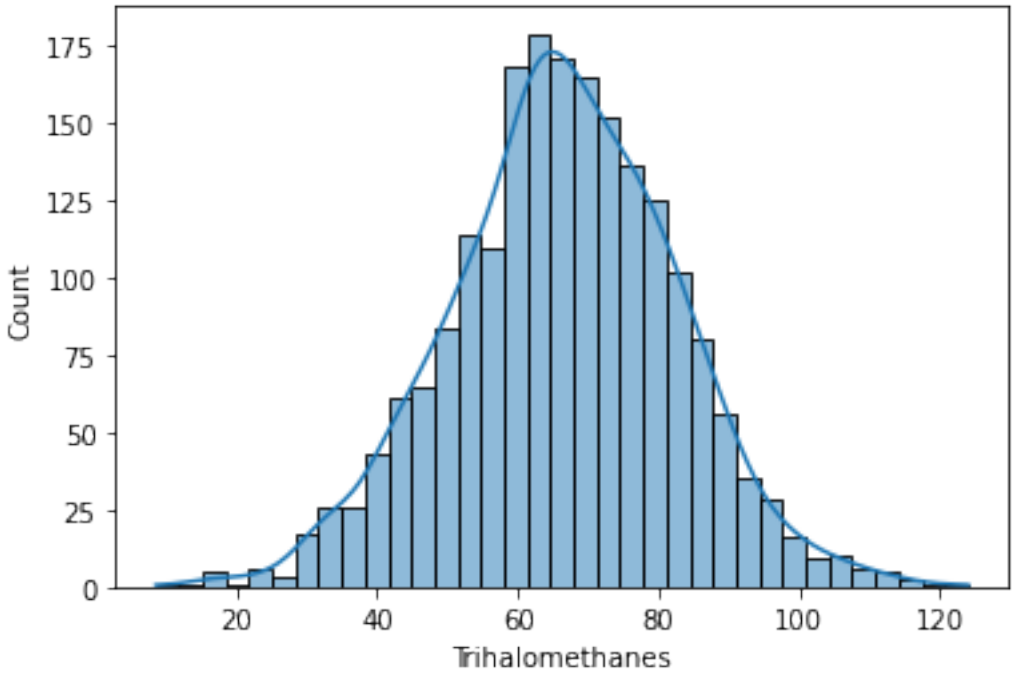

[ ]:
```
stat, p = stats.normaltest(df["Trihalomethanes"])
print('stat=%.3f, p=%.3f' % (stat, p))
if p > 0.05:
    print('Berdistribusi Normal')
else:
    print('Tidak Berdistribusi Normal')
```

```
stat=4.520, p=0.104
Berdistribusi Normal
```

Turbidity

[ ]:
```
sns.histplot(df["Turbidity"], kde=True)
```

[ ]:
```
<AxesSubplot:xlabel='Turbidity', ylabel='Count'>
```

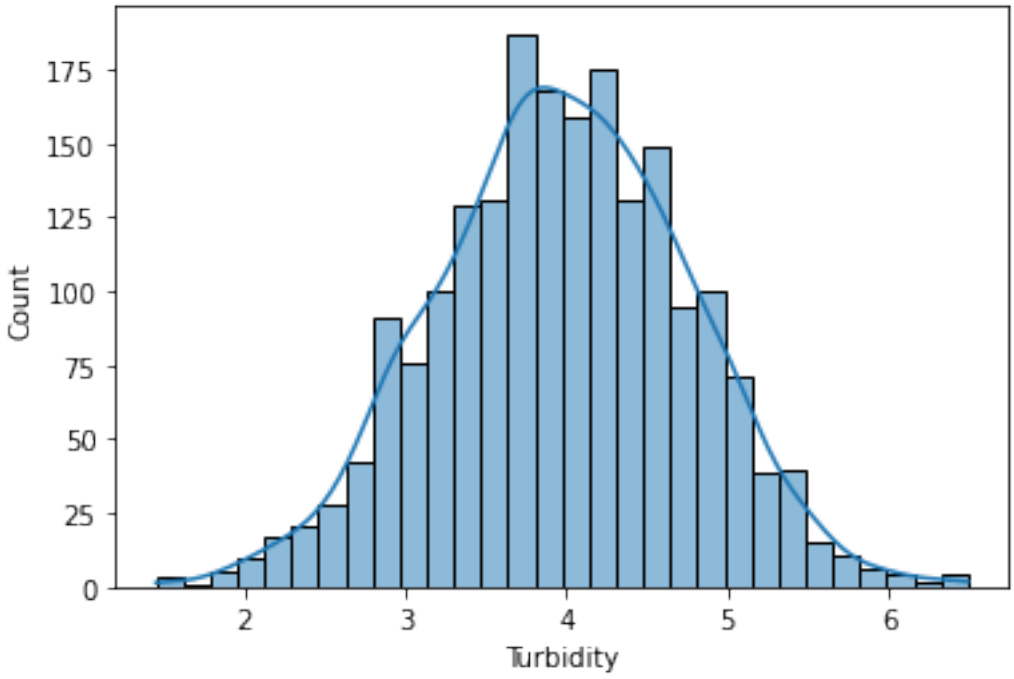

[ ]:
```
stat, p = stats.normaltest(df["Turbidity"])
print('stat=%.3f, p=%.3f' % (stat, p))
if p > 0.05:
    print('Berdistribusi Normal')
else:
    print('Tidak Berdistribusi Normal')
```

```
stat=0.524, p=0.769
Berdistribusi Normal
```

1.1.6 Soal 4

Melakukan test hipotesis 1 sampel, dengan menuliskan 6 langkah testing dan menampilkan juga boxplotnya untuk kolom/bagian yang bersesuaian.

[ ]:
```
def zScore1(X,u0,simpbaku,n):
    return (X-u0)/(simpbaku/n**(1/2))
def zScore2(p,p0,q0,n):
    return (p-p0)/(p0*q0/n)**(1/2)
```

a. Nilai Rata-rata pH di atas 7?

[ ]:
```
print("a. Nilai rata-rata pH di atas 7")

#1
H0 = " =7"
```

```
print("1. H0 : {}".format(H0))

#2
H1 = " >7"
print("2. H1 : {}".format(H1))

#3
  = 5e-2
print("3.   = {}".format( ))

#4
z  = round(stats.norm.ppf(1- ),3)
print("4. Uji Statistik : z=(x̄- 0)/( /sqrt(n)), one-tailed")
print("   Daerah Kritis : z>z  : z >{}".format(z ))

#5
X = df["pH"].mean()
u0= 7
simpbaku = df["pH"].std()
n = len( df["pH"])
z = round(zScore1(X,u0,simpbaku,n),3)
p_value = 1-stats.norm.cdf(z)
print("5. Komputasi")
print("   x̄ : {} \n   n: {} \n    : {} \n    0 : {}".format(X,n,simpbaku,u0))
print("   p_value : {} \n   z: {}".format(str(p_value),str(z)))

#6
print("6. Test Daerah Kritis")
if (z > z ):
    print("   Tolak H0 karena nilai uji = {}>{}".format(str(z),str(z )))
    print("   Rata-Rata pH>7")
else :
    print("   Terima H0 karena nilai uji = {}<={}".format(str(z),str(z )))
    print("   Rata-Rata pH=7")

sns.boxplot(data = df["pH"])
```

```
a. Nilai rata-rata pH di atas 7
1. H0 :  =7
2. H1 :  >7
3.   = 0.05
4. Uji Statistik : z=(x̄- 0)/( /sqrt(n)), one-tailed
   Daerah Kritis : z>z  : z >1.645
5. Komputasi
   x̄ : 7.0871927687138285
   n: 2010
    : 1.5728029470456655
```

```
    0 : 7
   p_value : 0.006477571731867804
   z: 2.485
6. Test Daerah Kritis
   Tolak H0 karena nilai uji = 2.485>1.645
   Rata-Rata pH>7
```

[ ]: <AxesSubplot:>

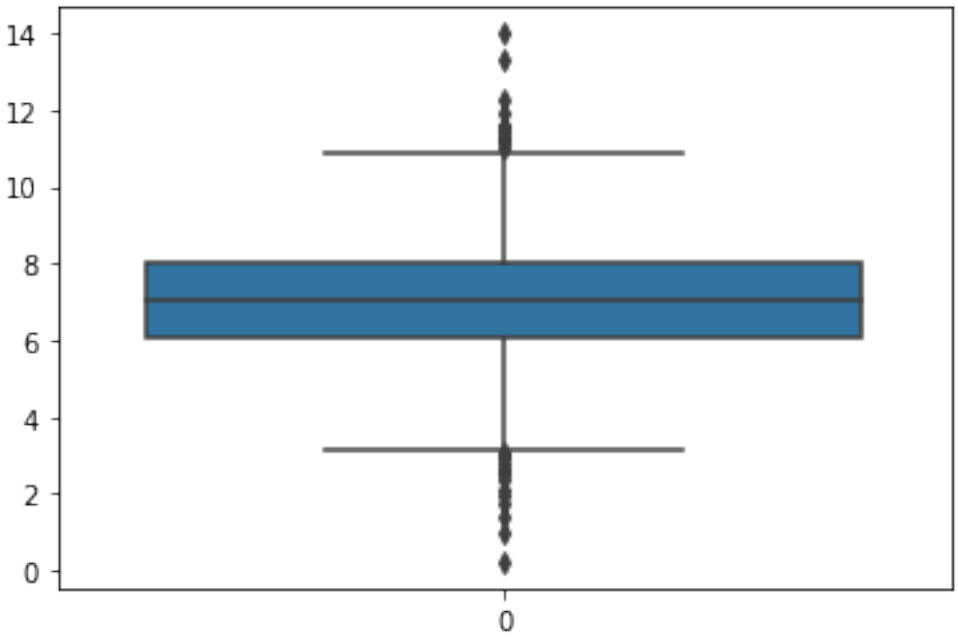

b. Nilai Rata-rata Hardness tidak sama dengan 205?

[ ]:
```
print("b. Nilai Rata-rata Hardness tidak sama dengan 205?")

#1
H0 = " =205"
print("1. H0 : {}".format(H0))

#2
H1 = " 205"
print("2. H1 : {}".format(H1))

#3
  = 5e-2
print("3.   = {}".format( ))

#4
```

```
z 2 = round(stats.norm.ppf(1-( /2)),3)
print("4. Uji Statistik : z=(x̄- 0)/( /sqrt(n)), two-tailed")
print("   Daerah Kritis : z>z /2 atau z <-z /2 : z>{} atau z<{}".
  ↪format(z 2,-1*z 2))

#5
X = df["Hardness"].mean()
u0= 205
simpbaku = df["Hardness"].std()
n = len( df["Hardness"])
z = round(zScore1(X,u0,simpbaku,n),3)
p_value = 1-abs(stats.norm.cdf(z)-stats.norm.cdf(-1*z))
print("5. Komputasi")
print("   x̄ : {} \n   n: {} \n    : {} \n    0 : {}".format(X,n,simpbaku,u0))
print("   p_value : {} \n   z: {}".format(str(p_value),str(z)))

#6
print("6. Test Daerah Kritis")
if (z > z 2 or z<-1*z 2):
    if (z > z 2):
        print("   Tolak H0 karena nilai uji = {}>{}".format(z,z 2))
    else:
        print("   Tolak H0 karena nilai uji = {}<{} ".format(z,-1*z 2))
    print("   Rata-rata hardness 205")
else :
    print("   Terima H0 karena nilai uji = {}<{}<{} ".format(-1*z 2,z,z 2))
    print("   Rata-rata hardness = 205")

sns.boxplot(data = df["Hardness"])
```

```
b. Nilai Rata-rata Hardness tidak sama dengan 205?
1. H0 :  =205
2. H1 :   205
3.   = 0.05
4. Uji Statistik : z=(x̄- 0)/( /sqrt(n)), two-tailed
   Daerah Kritis : z>z /2 atau z <-z /2 : z>1.96 atau z<-1.96
5. Komputasi
   x̄ : 195.96920903783524
   n: 2010
    : 32.643165859429864
    0 : 205
   p_value : 0.0
   z: -12.403
6. Test Daerah Kritis
   Tolak H0 karena nilai uji = -12.403<-1.96
   Rata-rata hardness 205
```

[ ]: <AxesSubplot:>

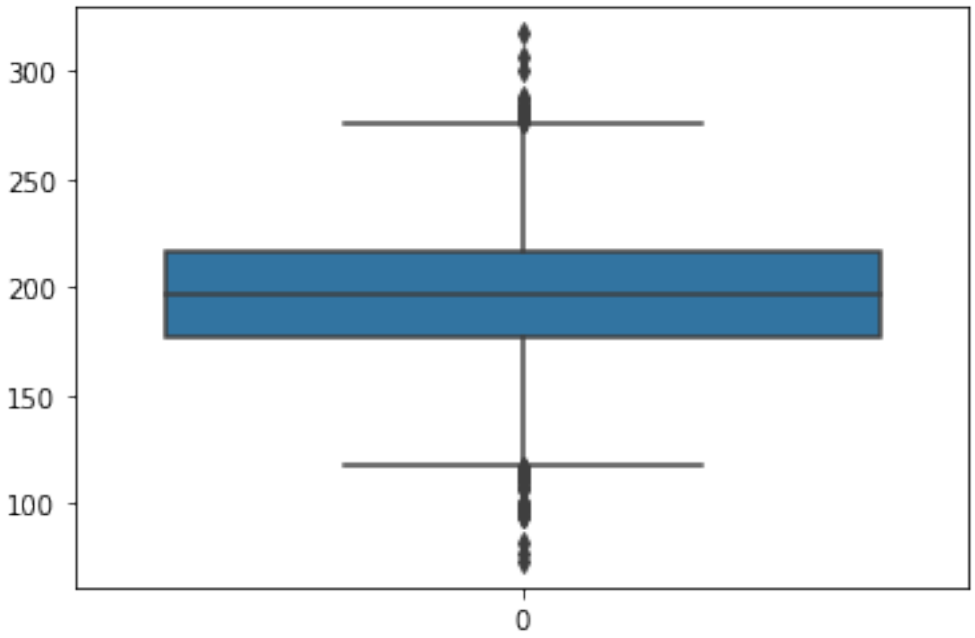

c. Nilai Rata-rata 100 baris pertama kolom Solids bukan 21900?

[ ]:
```
print("c. Nilai Rata-rata 100 baris pertama kolom Solids bukan 21900?")

#1
H0 = " =21900"
print("1. H0 : {}".format(H0))

#2
H1 = " 21900"
print("2. H1 : {}".format(H1))

#3
  = 5e-2
print("3.   = {}".format( ))

#4
z 2 = round(stats.norm.ppf(1-( /2)),3)
print("4. Uji Statistik : z=(x̄- 0)/( /sqrt(n)) ")
print("   Daerah Kritis : z>z /2 atau z <-z /2 : z>{} atau z<{}".
 ↪format(z 2,-1*z 2))

#5
data = df["Solids"][:100]
```

```
X = data.mean()
u0= 21900
simpbaku =  df["Solids"].std()
n = len(  df["Solids"])
z = round(zScore1(X,u0,simpbaku,n),3)
p_value =  1-abs(stats.norm.cdf(z)-stats.norm.cdf(-1*z))
print("5. Komputasi")
print("   x̄ : {} \n   n: {} \n    : {} \n    0 : {}".format(X,n,simpbaku,u0))
print("   p_value : {} \n   z: {}".format(str(p_value),str(z)))

#6
print("6. Test Daerah Kritis")
if (z > z 2 or z<-1*z 2):
    if (z > z 2):
        print("   Tolak H0 karena nilai uji = {}>{} ".format(z,z 2))
    else:
        print("   Tolak H0 karena nilai uji = {}<{} ".format(z,-1*z 2))
    print("   Nilai Rata-rata 100 baris pertama kolom Solids   21900")
else :
    print("   Terima H0 karena nilai uji = {}<{}<{}".format(-1*z 2,z,z 2))
    print("   Nilai Rata-rata 100 baris pertama kolom Solids = 21900")

sns.boxplot(data = df["Solids"])
```

```
c. Nilai Rata-rata 100 baris pertama kolom Solids bukan 21900?
1. H0 :  =21900
2. H1 :   21900
3.   = 0.05
4. Uji Statistik : z=(x̄- 0)/( /sqrt(n))
   Daerah Kritis : z>z /2 atau z <-z /2 : z>1.96 atau z<-1.96
5. Komputasi
   x̄ : 22347.334446383426
   n: 2010
    : 8625.397911190576
    0 : 21900
   p_value : 0.020071960200548133
   z: 2.325
6. Test Daerah Kritis
   Tolak H0 karena nilai uji = 2.325>1.96
   Nilai Rata-rata 100 baris pertama kolom Solids   21900
```

[ ]: <AxesSubplot:>

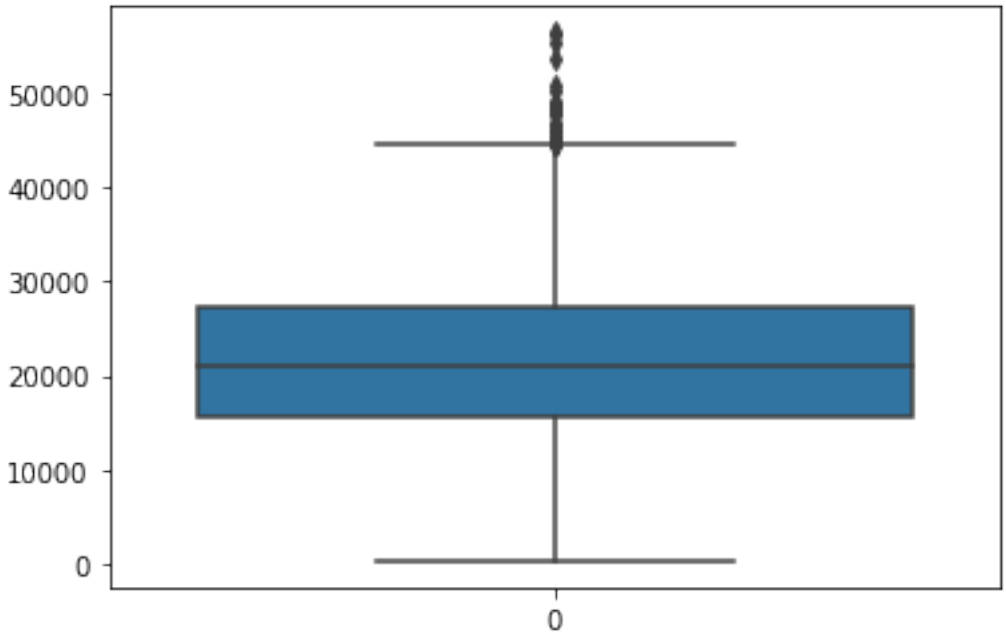

d. Proporsi nilai Conductivity yang lebih dari 450, adalah tidak sama dengan 10%?

[ ]:
```
print("d. Proporsi nilai Conductivity yang lebih dari 450, adalah tidak sama␣
 ↪dengan 10%")

#1
H0 = "p = 0,10"
print("1. H0 : {}".format(H0))

#2
H1 = "p 0,10"
print("2. H1 : {}".format(H1))

#3
 = 5e-2
print("3.   = {}".format( ))

#4
z 2 = round(stats.norm.ppf(1-( /2)),3)
print("4. Uji Statistik : z=(p̂-p0)/sqrt(p0*q0/n),   diketahui")
print("   Daerah Kritis : z>z /2 atau z <-z /2 : z>{} atau z<{}".
 ↪format(z 2,-1*z 2))

#5
data = [item for item in df["Conductivity"] if item >450]
p = len(data)/len(df["Conductivity"])
```

```
p0 = 0.1
q0= 1-p0
n = len(  df["Conductivity"])
z = round(zScore2(p,p0,q0,n),3)
p_value =  1-abs(stats.norm.cdf(z)-stats.norm.cdf(-1*z))
print("5. Komputasi")
print("   p̂ : {} \n   n: {} \n   p0: {} \n   q0 : {}".format(p,n,p0,q0))
print("   p_value : {} \n   z: {}".format(str(p_value),str(z)))

#6
print("6. Test Daerah Kritis")
if (z > z 2 or z<-1*z 2):
    if (z > z 2):
        print("   Tolak H0 karena nilai uji = {}>{} ".format(z,z 2))
    else:
        print("   Tolak H0 karena nilai uji = {}<{} ".format(z,-1*z 2))
    print("   Proporsi nilai Conductivity yang lebih dari 450   10%")
else :
    print("   Terima H0 karena nilai uji = {}<{}<{} ".format(-1*z 2,z,z 2))
    print("   Proporsi nilai Conductivity yang lebih dari 450 = 10%")

sns.boxplot(data = df["Conductivity"])
```

```
d. Proporsi nilai Conductivity yang lebih dari 450, adalah tidak sama dengan 10%
1. H0 : p = 0,10
2. H1 : p 0,10
3.   = 0.05
4. Uji Statistik : z=(p̂-p0)/sqrt(p0*q0/n),   diketahui
   Daerah Kritis : z>z /2 atau z <-z /2 : z>1.96 atau z<-1.96
5. Komputasi
   p̂ : 0.3706467661691542
   n: 2010
   p0: 0.1
   q0 : 0.9
   p_value : 0.0
   z: 40.446
6. Test Daerah Kritis
   Tolak H0 karena nilai uji = 40.446>1.96
   Proporsi nilai Conductivity yang lebih dari 450   10%
```

[ ]: <AxesSubplot:>

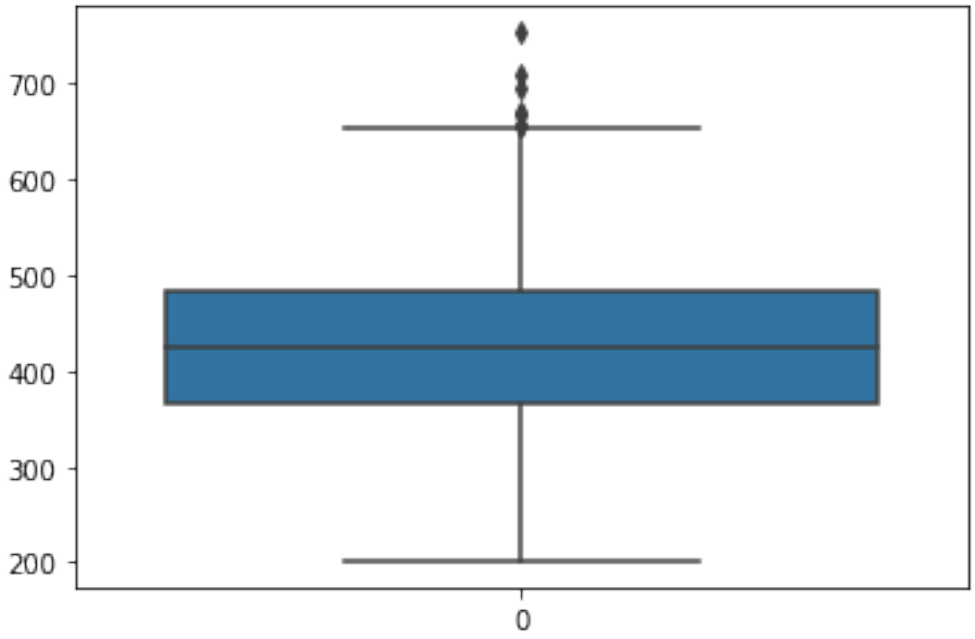

e. Proporsi nilai Trihalomethanes yang kurang dari 40, adalah kurang dari 5%?

```
[ ]: print("e.Proporsi nilai Trihalomethanes yang kurang dari 40, adalah kurang dari␣
      ↪5%?")

     #1
     H0 = "p = 0,05"
     print("1. H0 : {}".format(H0))

     #2
     H1 = "p<0,05"
     print("2. H1 : {}".format(H1))

     #3
      = 5e-2
     print("3.   = {}".format( ))

     #4
     z  = round(stats.norm.ppf(1- ),3)
     print("4. Uji Statistik : z=(p̂-p0)/sqrt(p0*q0/n),   diketahui")
     print("   Daerah Kritis : z <-z  : z<{}".format(-1*z ))

     #5
     data = [item for item in df["Trihalomethanes"] if item <40]
     p = len(data)/len(df["Trihalomethanes"])
     p0 = 0.05
```

```
q0= 1-p0
n = len(  df["Trihalomethanes"])
z = round(zScore2(p,p0,q0,n),3)
p_value = 1-stats.norm.cdf(z)
print("5. Komputasi")
print("   p̂ : {} \n   n: {} \n   p0: {} \n   q0 : {}".format(p,n,p0,q0))
print("   p_value : {} \n   z: {}".format(str(p_value),str(z)))

#6
print("6. Test Daerah Kritis")
if (z < -1*z ):
    print("   Tolak H0 karena nilai uji = {}<{}".format(str(z),str(-1*z )))
    print("   Proporsi nilai Trihalomethanes yang kurang dari 40, adalah kurang␣
 ↪dari 5%")
else :
    print("   Terima H0 karena nilai uji = {}>={}".format(str(z),str( )))
    print("   Proporsi nilai Trihalomethanes yang kurang dari 40, adalah sama␣
 ↪dengan 5%")

sns.boxplot(data = df["Trihalomethanes"])
```

```
e.Proporsi nilai Trihalomethanes yang kurang dari 40, adalah kurang dari 5%?
1. H0 : p = 0,05
2. H1 : p<0,05
3.   = 0.05
4. Uji Statistik : z=(p̂-p0)/sqrt(p0*q0/n),   diketahui
   Daerah Kritis : z <-z  : z<-1.645
5. Komputasi
   p̂ : 0.0527363184079602
   n: 2010
   p0: 0.05
   q0 : 0.95
   p_value : 0.2867174419702131
   z: 0.563
6. Test Daerah Kritis
   Terima H0 karena nilai uji = 0.563>=0.05
   Proporsi nilai Trihalomethanes yang kurang dari 40, adalah sama dengan 5%
```

[ ]: <AxesSubplot:>

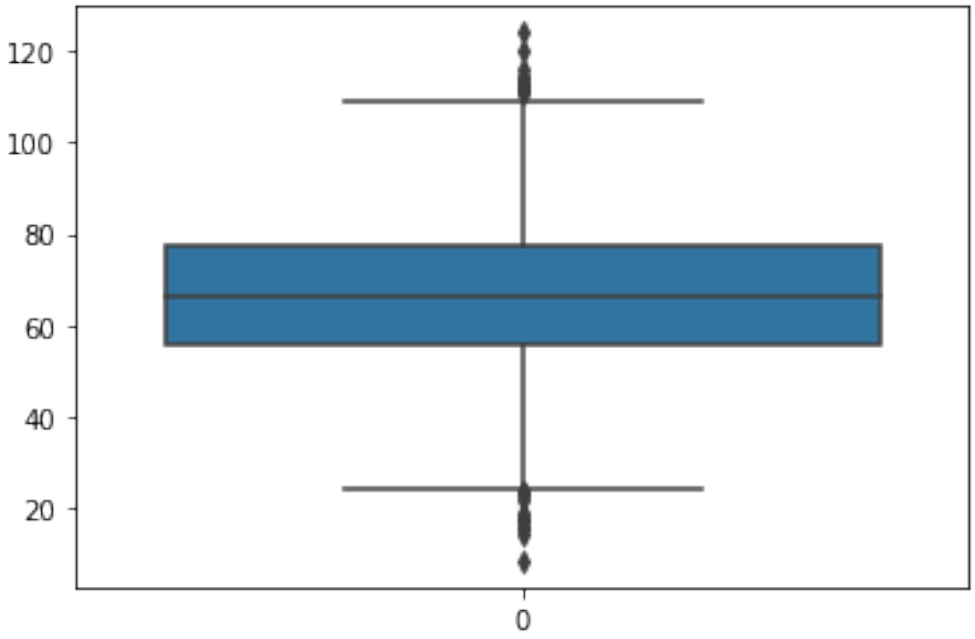

1.1.7 Soal 5

Melakukan test hipotesis 2 sampel, dengan menuliskan 6 langkah testing dan menampilkan juga boxplotnya untuk kolom/bagian yang bersesuaian.

[ ]:
```
def zScore(d0, x1, x2, v1, v2, n1, n2):
  return((x1 - x2) - d0)/(((v1/n1) + (v2/n2))**0.5)
```

a. Data kolom Sulfate dibagi 2 sama rata: bagian awal dan bagian akhir kolom. Benarkah rata-rata kedua bagian tersebut sama? Rata-rata Bagian Awal Kolom Sulfate

[ ]:
```
df['Sulfate'].iloc[:len(df)//2].mean()
```

[ ]:
```
331.30532950549565
```

[ ]:
```
df.iloc[:len(df)//2].boxplot(['Sulfate'])
```

[ ]:
```
<AxesSubplot:>
```

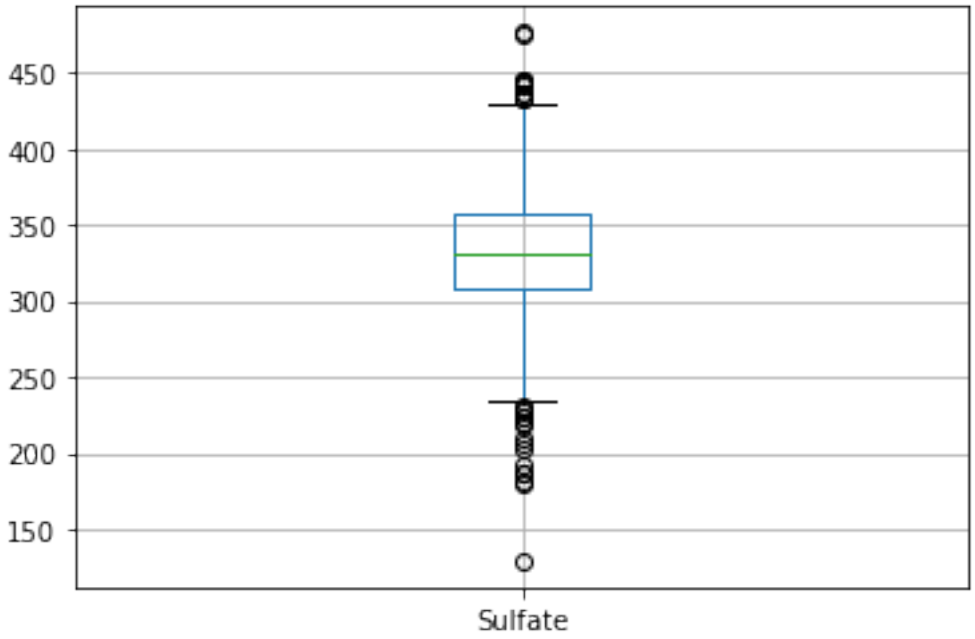

Rata-rata Bagian Akhir Kolom Sulfate

```
[ ]: df['Sulfate'].iloc[len(df)//2:].mean()
```

```
[ ]: 335.11742332488245
```

```
[ ]: df.iloc[len(df)//2:].boxplot(['Sulfate'])
```

```
[ ]: <AxesSubplot:>
```

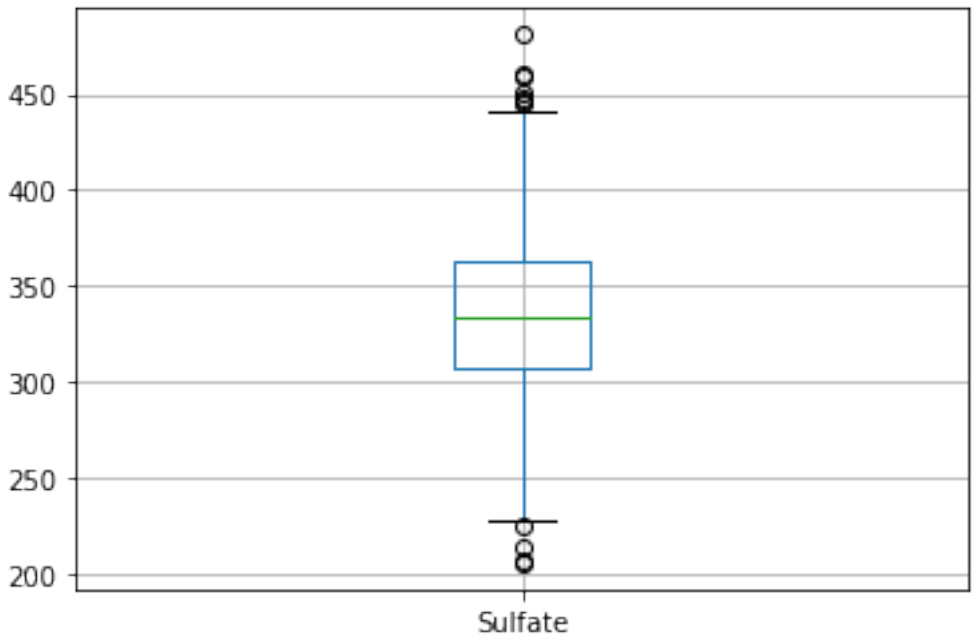

Enam Langkah Testing SulfateAwal dan SulfateAkhir

1. Hipotesis Nol
   $H_0 : \mu_{SulfateAwal} = \mu_{SulfateAkhir}$
2. Hipotesis Alternatif
   $H_1 : \mu_{SulfateAwal} \neq \mu_{SulfateAkhir}$
3. Tingkat Signifikan
   $\alpha = 0.05$
4. Penentuan uji statistik dan daerah kritis

Uji Statistik: z-test (two-tailed)

[ ]:
```
zalpha = stats.norm.ppf(1 - 0.05/2)
print('z < %.2f atau z > %.2f' % (-zalpha, zalpha))
```

```
z < -1.96 atau z > 1.96
```

5. Perhitungan uji statistik dan p-value

[ ]:
```
bagianAwal = df['Sulfate'].iloc[:len(df)//2]
bagianAkhir = df['Sulfate'].iloc[len(df)//2:]

meanAwal = bagianAwal.mean()
meanAkhir = bagianAkhir.mean()

varAwal = bagianAwal.var()
varAkhir = bagianAkhir.var()
```

```
z = zScore(0, meanAwal, meanAkhir, varAwal, varAkhir, len(bagianAwal),␣
 ↪len(bagianAkhir))
p = 2 * (1 - stats.norm.cdf(abs(z)))

print("z:", z)
print("p-value:", p)
```

```
z: -2.0752690696871983
p-value: 0.03796160438512852
```

6. Keputusan

[ ]:
```
if z < -zalpha or z > zalpha:
  print("Hipotesis Null ditolak")
else:
  print("Hipotesis Null diterima")
```

```
Hipotesis Null ditolak
```

b. Data kolom OrganicCarbon dibagi 2 sama rata: bagian awal dan bagian akhir kolom. Benarkah rata-rata bagian awal lebih besar dari pada bagian akhir sebesar 0.15? Rata-rata Bagian Awal Kolom OrganicCarbon

[ ]:
```
df['OrganicCarbon'].iloc[:len(df)//2].mean()
```

[ ]:
```
14.253972723723393
```

[ ]:
```
df.iloc[:len(df)//2].boxplot(['OrganicCarbon'])
```

[ ]:
```
<AxesSubplot:>
```

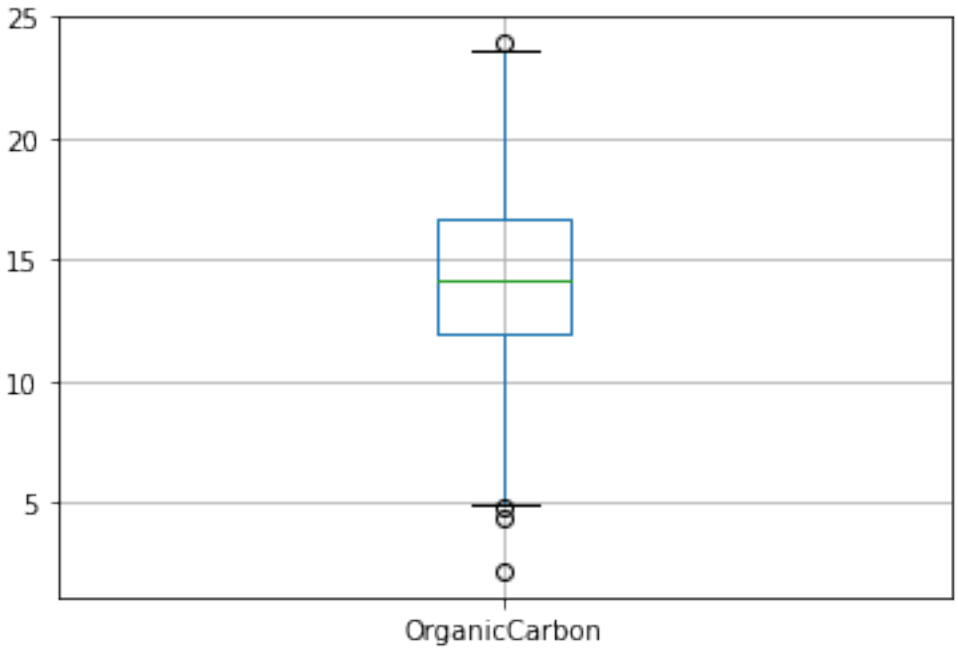

Rata-rata Bagian Akhir Kolom OrganicCarbon

[ ]:
```
df['OrganicCarbon'].iloc[len(df)//2:].mean()
```

[ ]:
```
14.461907080372756
```

[ ]:
```
df.iloc[len(df)//2:].boxplot(['OrganicCarbon'])
```

[ ]:
```
<AxesSubplot:>
```

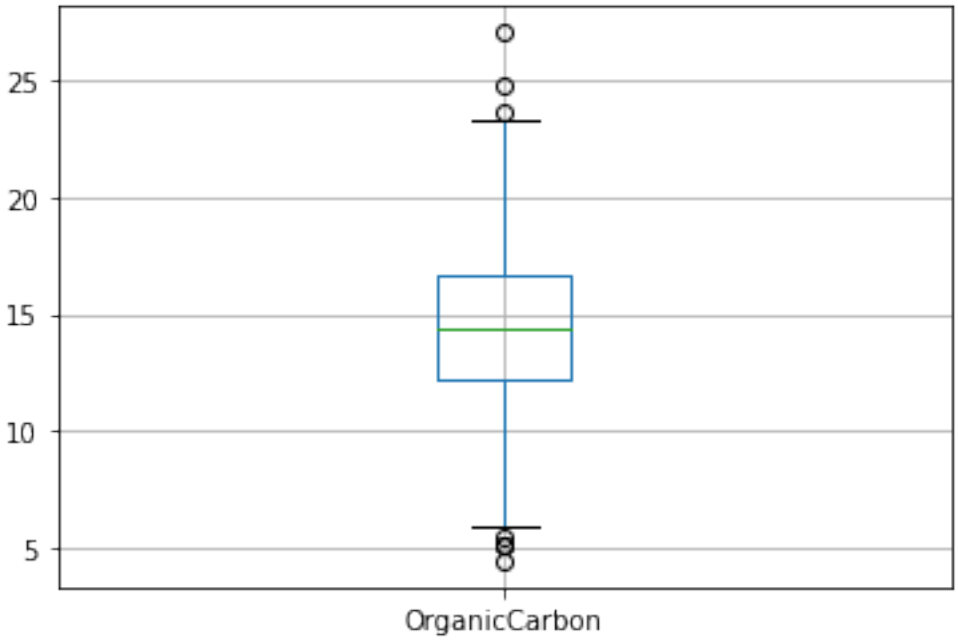

Enam Langkah Testing OrganicCarbonAwal dan OrganicCarbonAkhir

1. Hipotesis Nol
   $H_0 : \mu_{OrganicCarbonAwal} = \mu_{OrganicCarbonAkhir} + 0.15$
2. Hipotesis Alternatif
   $H_1 : \mu_{OrganicCarbonAwal} \neq \mu_{OrganicCarbonAkhir} + 0.15$
3. Tingkat Signifikan
   $\alpha = 0.05$
4. Penentuan uji statistik dan daerah kritis

Uji Statistik: z-test (two-tailed)

[ ]:
```
zalpha = stats.norm.ppf(1 - 0.05/2)
print('z < %.2f atau z > %.2f' % (-zalpha, zalpha))
```

```
z < -1.96 atau z > 1.96
```

5. Perhitungan uji statistik dan p-value

[ ]:
```
bagianAwal = df['OrganicCarbon'].iloc[:len(df)//2]
bagianAkhir = df['OrganicCarbon'].iloc[len(df)//2:]

meanAwal = bagianAwal.mean()
meanAkhir = bagianAkhir.mean()

varAwal = bagianAwal.var()
varAkhir = bagianAkhir.var()
```

```
z = zScore(0.15, meanAwal, meanAkhir, varAwal, varAkhir, len(bagianAwal),␣
 ↪len(bagianAkhir))
p = 2 * (1 - stats.norm.cdf(abs(z)))

print("z:", z)
print("p-value:", p)
```

```
z: -2.413145517798807
p-value: 0.015815503817599996
```

6. Keputusan

[ ]:
```
if z < -zalpha or z > zalpha:
  print("Hipotesis Null ditolak")
else:
  print("Hipotesis Null diterima")
```

```
Hipotesis Null ditolak
```

c. Rata-rata 100 baris pertama kolom Chloramines sama dengan 100 baris terakhirnya?

Rata-rata 100 Baris Pertama Kolom Chloramines

[ ]:
```
df['Chloramines'].iloc[:100].mean()
```

[ ]:
```
7.007771140423921
```

[ ]:
```
df.iloc[:100].boxplot(['Chloramines'])
```

[ ]:
```
<AxesSubplot:>
```

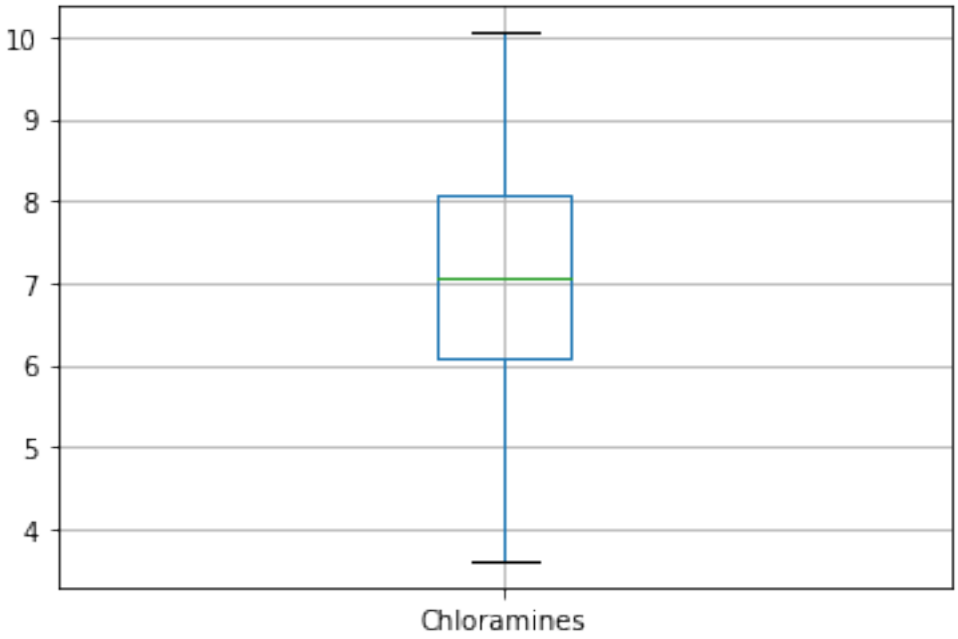

Rata-rata 100 Baris Terakhir Kolom Chloramines

[ ]:
```
df['Chloramines'].iloc[-100:].mean()
```

[ ]:
```
7.147197636249925
```

[ ]:
```
df.iloc[-100:].boxplot(['Chloramines'])
```

[ ]:
```
<AxesSubplot:>
```

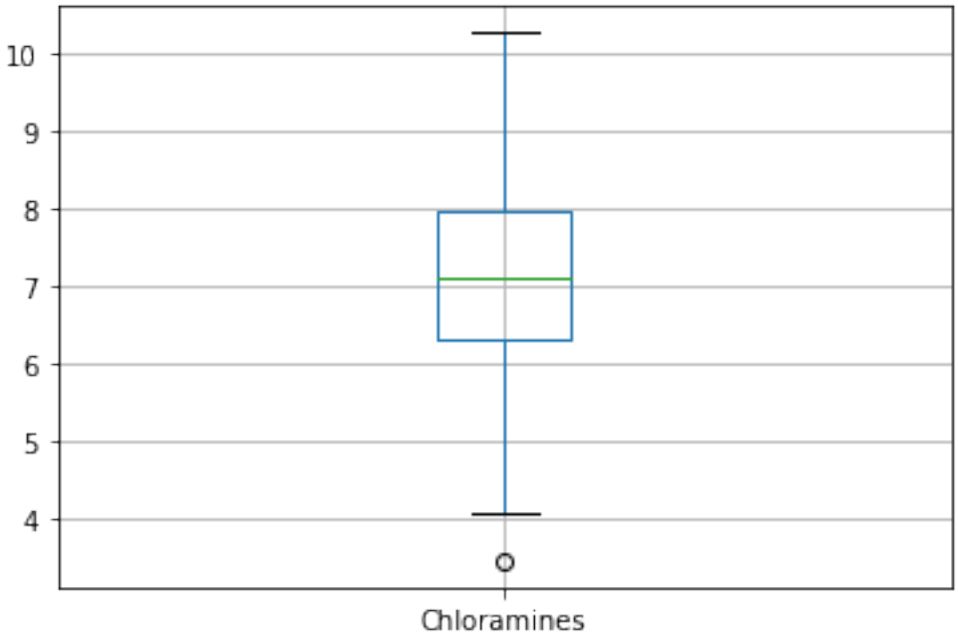

Enam Langkah Testing ChloraminesAwal dan ChloraminesAkhir:

1. Hipotesis Nol
   $H_0 : \mu_{ChloraminesAwal} = \mu_{ChloraminesAkhir}$
2. Hipotesis Alternatif
   $H_1 : \mu_{ChloraminesAwal} \neq \mu_{ChloraminesAkhir}$
3. Tingkat Signifikan
   $\alpha = 0.05$
4. Penentuan uji statistik dan daerah kritis

Uji Statistik: z-test (two-tailed)

[ ]:
```
zalpha = stats.norm.ppf(1 - 0.05/2)
print('z < %.2f atau z > %.2f' % (-zalpha, zalpha))
```

```
z < -1.96 atau z > 1.96
```

5. Perhitungan uji statistik dan p-value

[ ]:
```
bagianAwal = df['Chloramines'].iloc[:100]
bagianAkhir = df['Chloramines'].iloc[-100:]

meanAwal = bagianAwal.mean()
meanAkhir = bagianAkhir.mean()

varAwal = bagianAwal.var()
varAkhir = bagianAkhir.var()
```

```
z = zScore(0, meanAwal, meanAkhir, varAwal, varAkhir, len(bagianAwal),␣
 ↪len(bagianAkhir))
p = 2 * (1 - stats.norm.cdf(abs(z)))

print("z:", z)
print("p-value:", p)
```

```
z: -0.7059424842236872
p-value: 0.48022390604502796
```

6. Keputusan

[ ]:
```
if z < -zalpha or z > zalpha:
  print("Hipotesis Null ditolak")
else:
  print("Hipotesis Null diterima")
```

```
Hipotesis Null diterima
```

d. Proporsi nilai bagian awal Turbidity yang lebih dari 4, adalah lebih besar daripada, proporsi nilai yang sama di bagian akhir Turbidity ? Bagian Awal Kolom Turbidity

[ ]:
```
df['Turbidity'].iloc[:len(df)//2].describe()
```

[ ]:
```
count    1005.000000
mean        3.942879
std         0.786455
min         1.496101
25%         3.403393
50%         3.964450
75%         4.496627
max         6.494249
Name: Turbidity, dtype: float64
```

[ ]:
```
df.iloc[:len(df)//2].boxplot(['Turbidity'])
```

[ ]:
```
<AxesSubplot:>
```

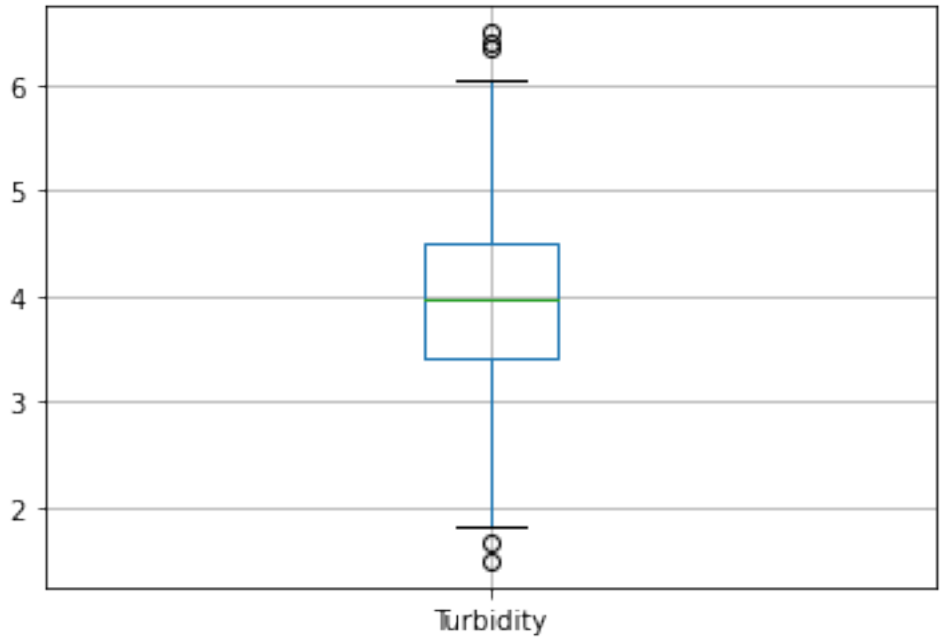

Bagian Akhir Kolom Turbidity

```
[ ]: df['Turbidity'].iloc[len(df)//2:].describe()
```

```
[ ]: count    1005.000000
     mean        3.996115
     std         0.773917
     min         1.450000
     25%         3.488675
     50%         3.969740
     75%         4.549917
     max         6.494749
     Name: Turbidity, dtype: float64
```

```
[ ]: df.iloc[len(df)//2:].boxplot(['Turbidity'])
```

```
[ ]: <AxesSubplot:>
```

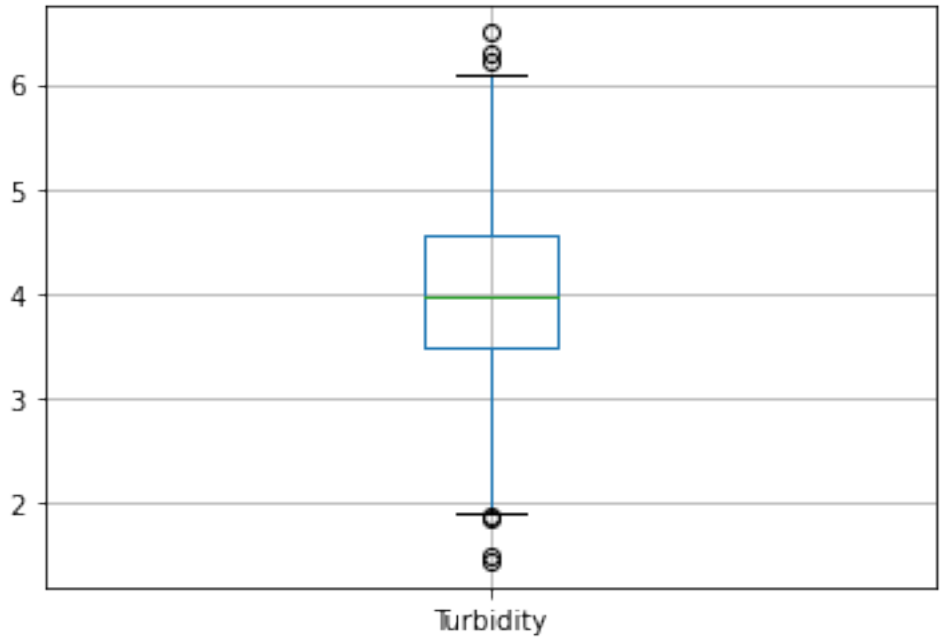

Enam Langkah Testing TurbidityAwal dan TurbidityAkhir:

X adalah variabel random TurbidityAwal
Y adalah variabel random TurbidityAkhir

1. Hipotesis Nol
   $H_0 : P(X > 4) = P(Y > 4)$
2. Hipotesis Alternatif
   $H_1 : P(X > 4) > P(Y > 4)$
3. Tingkat Signifikan
   $\alpha = 0.05$
4. Penentuan uji statistik dan daerah kritis

Uji Statistik: z-test (one-tailed)

[ ]:
```
zalpha = stats.norm.ppf(1 - 0.05)
print('z > %.2f' % (zalpha))
```

```
z > 1.64
```

5. Perhitungan uji statistik dan p-value

[ ]:
```
bagianAwal = df['Turbidity'].iloc[:len(df)//2]
bagianAkhir = df['Turbidity'].iloc[len(df)//2:]

bagianAwal2 = bagianAwal.loc[bagianAwal > 4]
bagianAkhir2 = bagianAkhir.loc[bagianAkhir > 4]
```

```
p1 = len(bagianAwal2) / len(bagianAwal)
p2 = len(bagianAkhir2) / len(bagianAkhir)

x = (len(bagianAwal2) + len(bagianAkhir2))/(len(bagianAwal) + len(bagianAkhir))
y = 1 - x

z = (p1 - p2) / ((x * y / len(bagianAwal)) + (x * y / len(bagianAkhir))**0.5)
p = 1 - stats.norm.cdf(z)

print("z:", z)
print("p-value:", p)
```

```
z: -0.18640972388732355
p-value: 0.5739382662410686
```

6. Keputusan

[ ]:
```
if z > zalpha:
  print("Hipotesis Null ditolak")
else:
  print("Hipotesis Null diterima")
```

```
Hipotesis Null diterima
```

e. Bagian awal kolom Sulfate memiliki variansi yang sama dengan bagian akhirnya?
Variansi Bagian Awal Kolom Sulfate

[ ]:
```
df['Sulfate'].iloc[:len(df)//2].var()
```

[ ]:
```
1708.3966020772502
```

[ ]:
```
df.iloc[:len(df)//2].boxplot(['Sulfate'])
```

[ ]:
```
<AxesSubplot:>
```

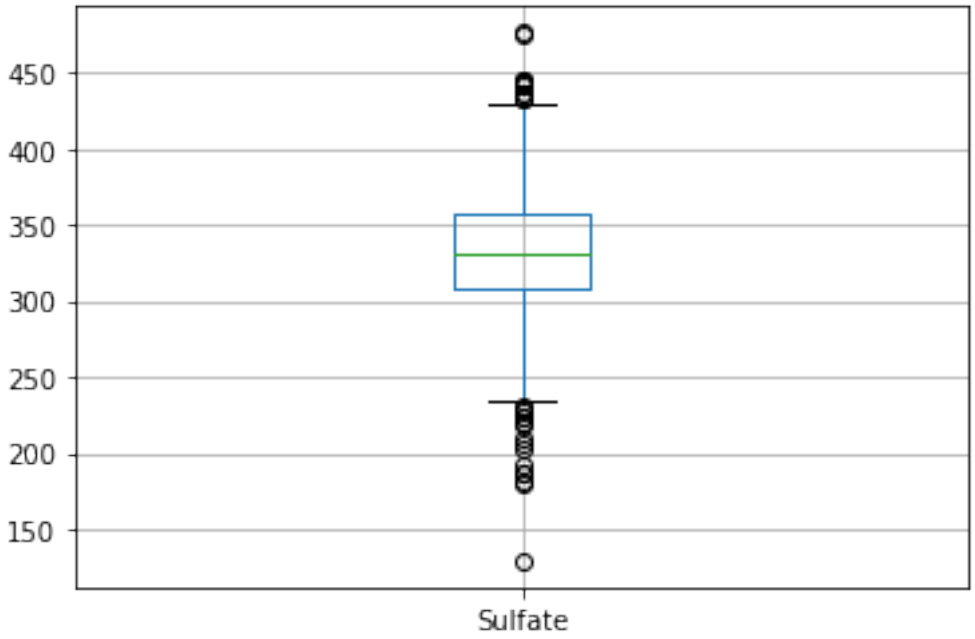

Variansi Bagian Akhir Kolom Sulfate

[ ]:
```
df['Sulfate'].iloc[len(df)//2:].var()
```

[ ]:
```
1682.7330644425087
```

[ ]:
```
df.iloc[len(df)//2:].boxplot(['Sulfate'])
```

[ ]:
```
<AxesSubplot:>
```

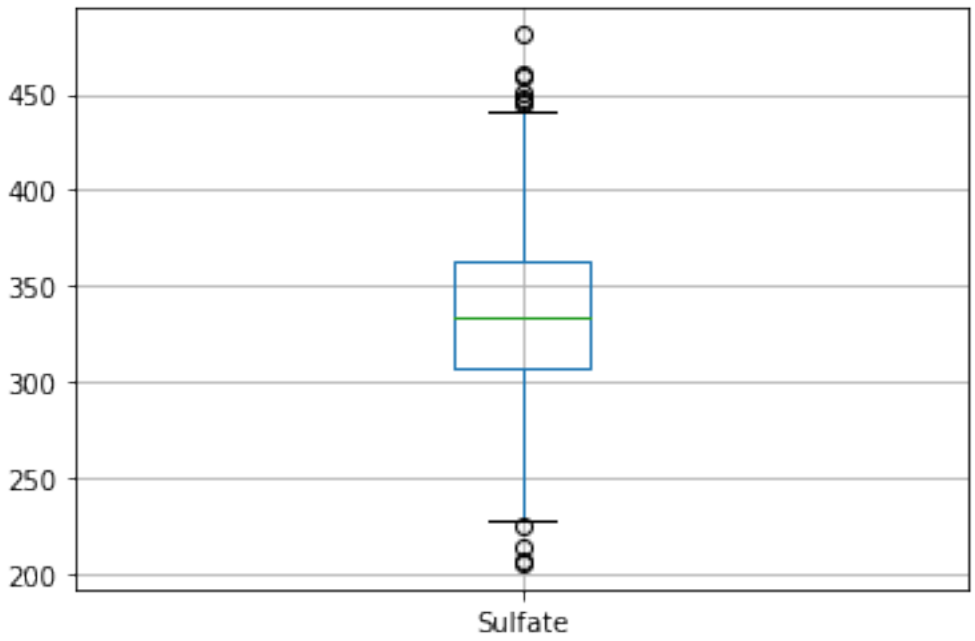

Enam Langkah Testing SulfateAwal dan SulfateAkhir:

1. Hipotesis Nol
   $H_0 : \sigma^2_{SulfateAwal} = \sigma^2_{SulfateAkhir}$
2. Hipotesis Alternatif
   $H_1 : \sigma^2_{SulfateAwal} \neq \sigma^2_{SulfateAkhir}$
3. Tingkat Signifikan
   $\alpha = 0.05$
4. Penentuan uji statistik dan daerah kritis

Uji Statistik: f-test

[ ]:
```
f1 = stats.f.ppf(q=1 - 0.05/2, dfn=len(bagianAwal) - 1, dfd=len(bagianAkhir) -␣
↪1)
f2 = 1 / (stats.f.ppf(q=1 - 0.05/2, dfn=len(bagianAkhir) - 1,␣
↪dfd=len(bagianAwal) - 1))
print('f < %.2f atau f > %.2f' % (f1, f2))
```

```
f < 1.13 atau f > 0.88
```

5. Perhitungan uji statistik dan p-value

[ ]:
```
bagianAwal = df['Sulfate'].iloc[:len(df)//2]
bagianAkhir = df['Sulfate'].iloc[len(df)//2:]

varAwal = bagianAwal.var()
varAkhir = bagianAkhir.var()
```

```
if varAwal > varAkhir:
  f = varAwal / varAkhir
else:
  f = varAkhir / varAwal

p = 2 * (1 - stats.f.cdf(f, len(bagianAkhir) - 1, len(bagianAwal) - 1))

print("f:", f)
print("p-value:", p)
```

```
f: 1.0152511043950063
p-value: 0.8105332960349165
```

6. Keputusan

[ ]:
```
if f > f1 or f < f2:
  print("Hipotesis Null ditolak")
else:
  print("Hipotesis Null diterima")
```

```
Hipotesis Null diterima
```

1.1.8 Soal 6

Test korelasi: tentukan apakah setiap kolom non-target berkorelasi dengan kolom target, dengan menggambarkan juga scatter plot nya. Gunakan correlation test.

a. Korelasi pH dengan Potability

[ ]:
```
korelasi = round(df["pH"].corr(df["Potability"]),2)
print("Nilai korelasi:",korelasi)
if(korelasi > 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪pH dan Potability merupakan korelasi positif")
elif(korelasi < 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪pH dan Potability merupakan korelasi negatif")
else:
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪pH dan Potability tidak berkorelasi")

sns.scatterplot(data = df, x = "pH", y = "Potability")
```

```
Nilai korelasi: 0.02
Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa pH dan
Potability merupakan korelasi positif
```

[ ]:
```
<AxesSubplot:xlabel='pH', ylabel='Potability'>
```

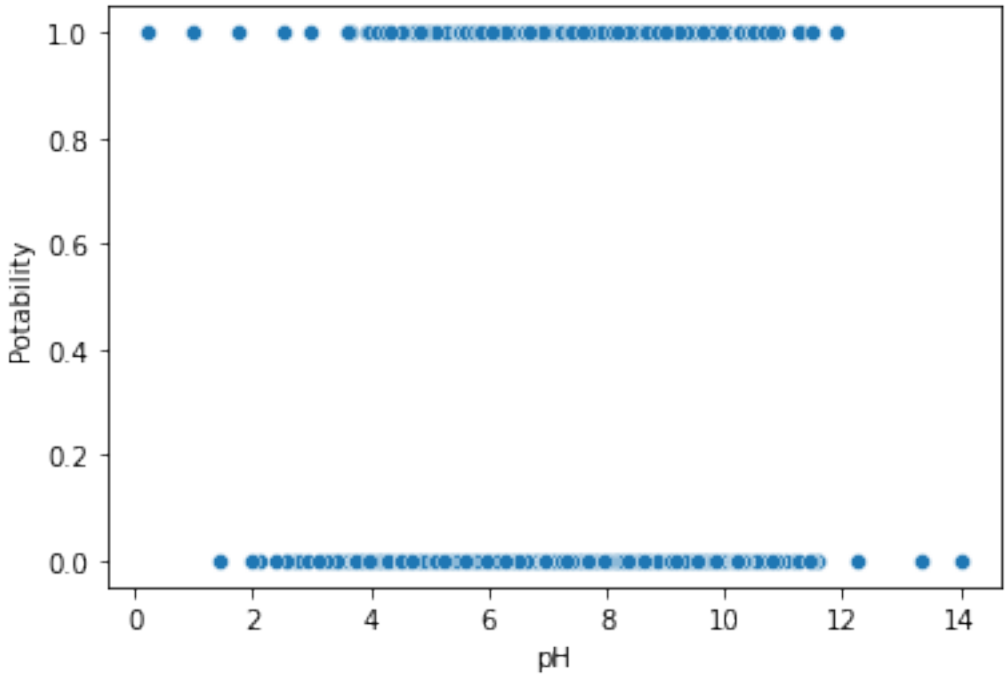

b. Korelasi Hardness dengan Potability

[ ]:
```
korelasi = round(df["Hardness"].corr(df["Potability"]),2)
print("Nilai korelasi:",korelasi)
if(korelasi > 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Hardness dan Potability merupakan korelasi positif")
elif(korelasi < 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Hardness dan Potability merupakan korelasi negatif")
else:
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Hardness dan Potability tidak berkorelasi")

sns.scatterplot(data = df, x = "Hardness", y = "Potability")
```

```
Nilai korelasi: -0.0
Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa Hardness dan
Potability tidak berkorelasi
```

[ ]:
```
<AxesSubplot:xlabel='Hardness', ylabel='Potability'>
```

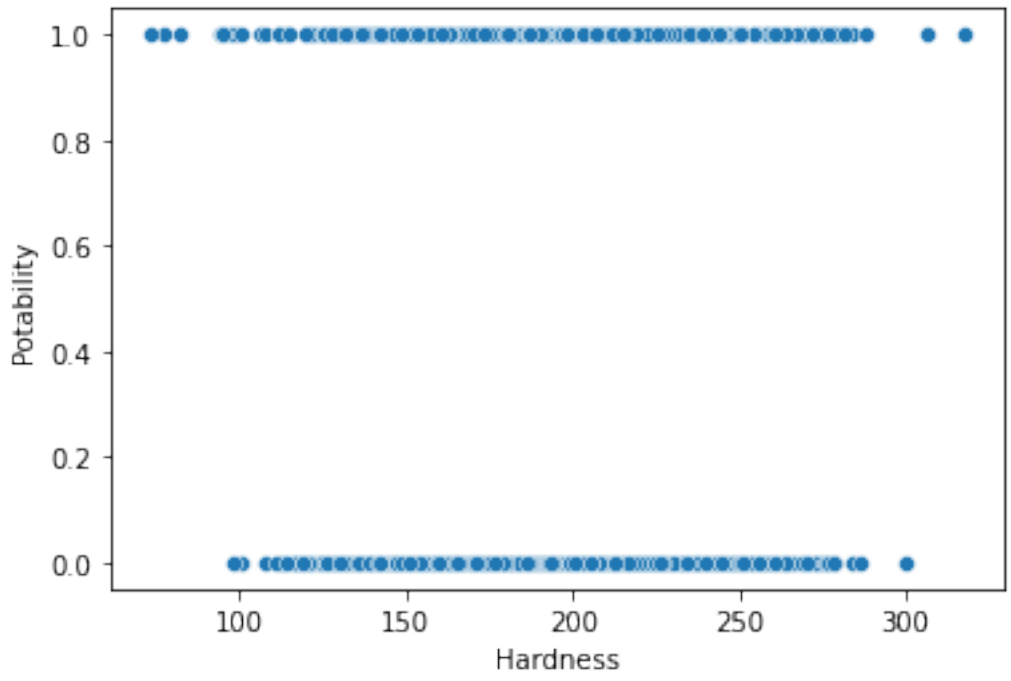

c. Korelasi Solids dengan Potability

[ ]:
```
korelasi = df["Solids"].corr(df["Potability"])
print("Nilai korelasi:",korelasi)
if(korelasi > 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Solids dan Potability merupakan korelasi positif")
elif(korelasi < 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Solids dan Potability merupakan korelasi negatif")
else:
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Solids dan Potability tidak berkorelasi")

sns.scatterplot(data = df, x = "Solids", y = "Potability")
```

```
Nilai korelasi: 0.03897657818173466
Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa Solids dan
Potability merupakan korelasi positif
```

[ ]:
```
<AxesSubplot:xlabel='Solids', ylabel='Potability'>
```

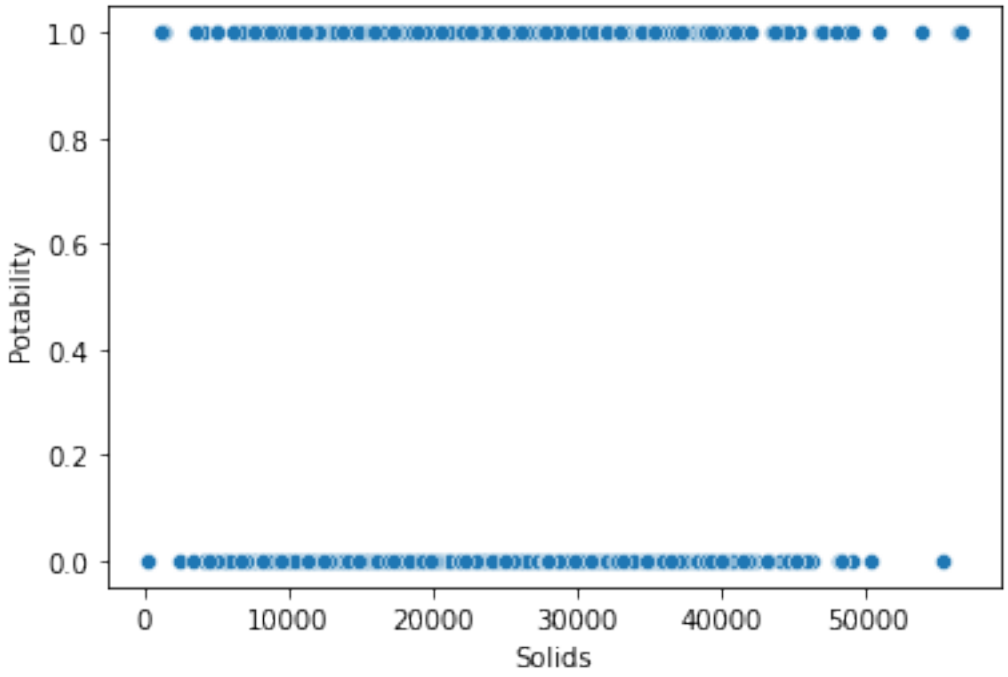

d. Korelasi Chloramines dengan Potability

[ ]:
```
korelasi = df["Chloramines"].corr(df["Potability"])
print("Nilai korelasi:",korelasi)
if(korelasi > 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Chloramines dan Potability merupakan korelasi positif")
elif(korelasi < 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Chloramines dan Potability merupakan korelasi negatif")
else:
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Chloramines dan Potability tidak berkorelasi")

sns.scatterplot(data = df, x = "Chloramines", y = "Potability")
```

```
Nilai korelasi: 0.02077892184052409
Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa Chloramines
dan Potability merupakan korelasi positif
```

[ ]:
```
<AxesSubplot:xlabel='Chloramines', ylabel='Potability'>
```

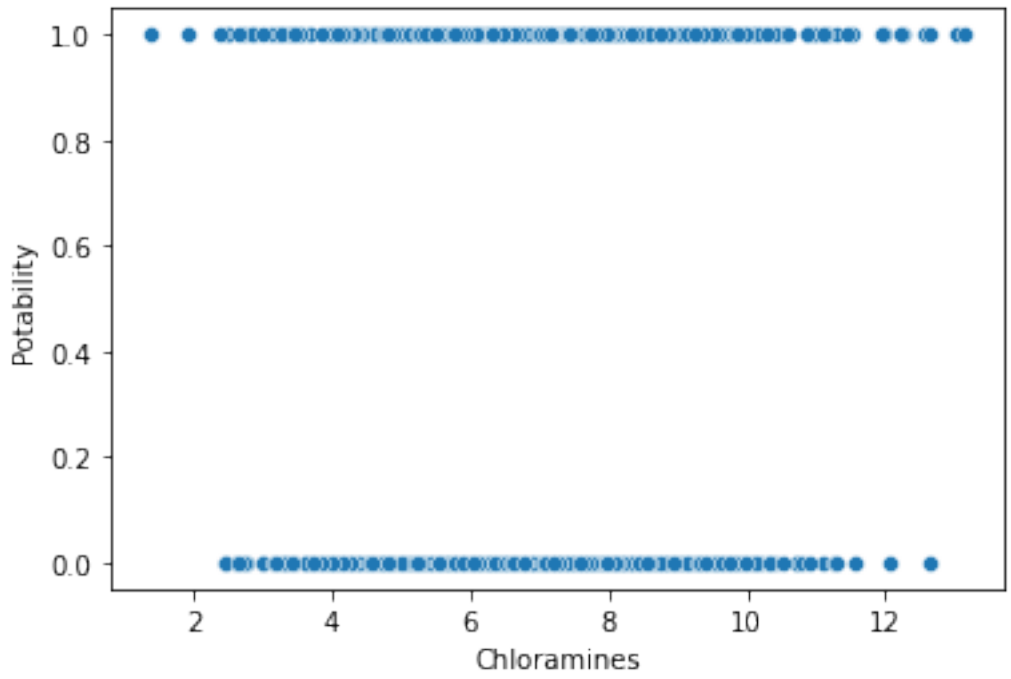

e. Korelasi Sulfate dengan Potability

[ ]:
```
korelasi = df["Sulfate"].corr(df["Potability"])
print("Nilai korelasi:",korelasi)
if(korelasi > 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Sulfate dan Potability merupakan korelasi positif")
elif(korelasi < 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Sulfate dan Potability merupakan korelasi negatif")
else:
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Sulfate dan Potability tidak berkorelasi")

sns.scatterplot(data = df, x = "Sulfate", y = "Potability")
```

```
Nilai korelasi: -0.015703164419273778
Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa Sulfate dan
Potability merupakan korelasi negatif
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate', ylabel='Potability'>
```

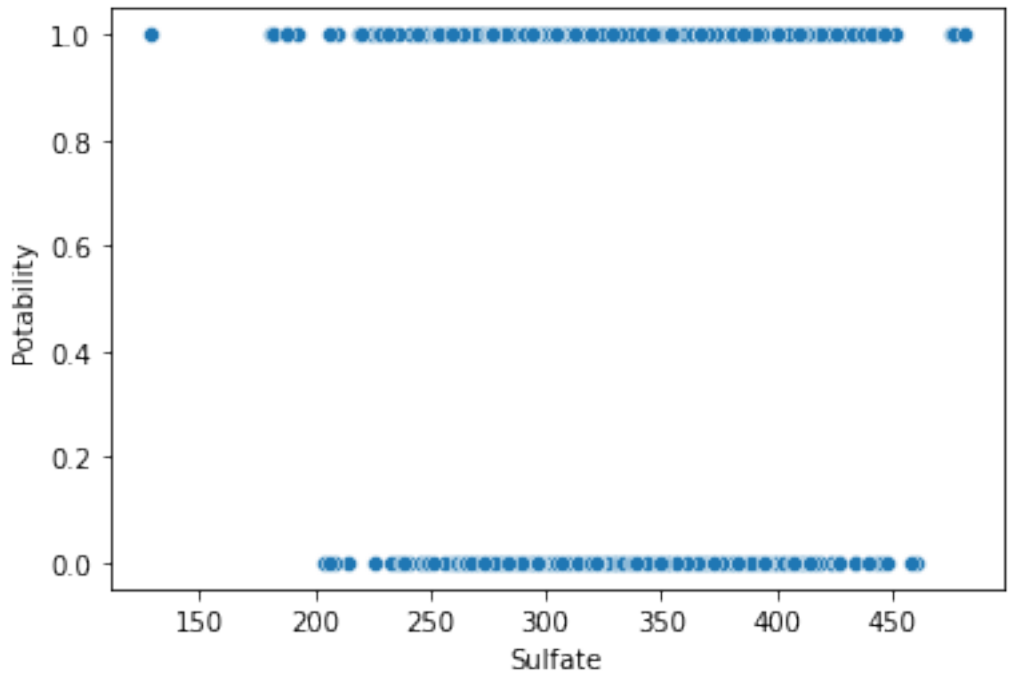

f. Korelasi Conductivity dengan Potability

[ ]:
```
korelasi = round(df["Conductivity"].corr(df["Potability"]),2)
print("Nilai korelasi:",korelasi)
if(korelasi > 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Conductivity dan Potability merupakan korelasi positif")
elif(korelasi < 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Conductivity dan Potability merupakan korelasi negatif")
else:
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Conductivity dan Potability tidak berkorelasi")

sns.scatterplot(data = df, x = "Conductivity", y = "Potability")
```

```
Nilai korelasi: -0.02
Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa Conductivity
dan Potability merupakan korelasi negatif
```

[ ]:
```
<AxesSubplot:xlabel='Conductivity', ylabel='Potability'>
```

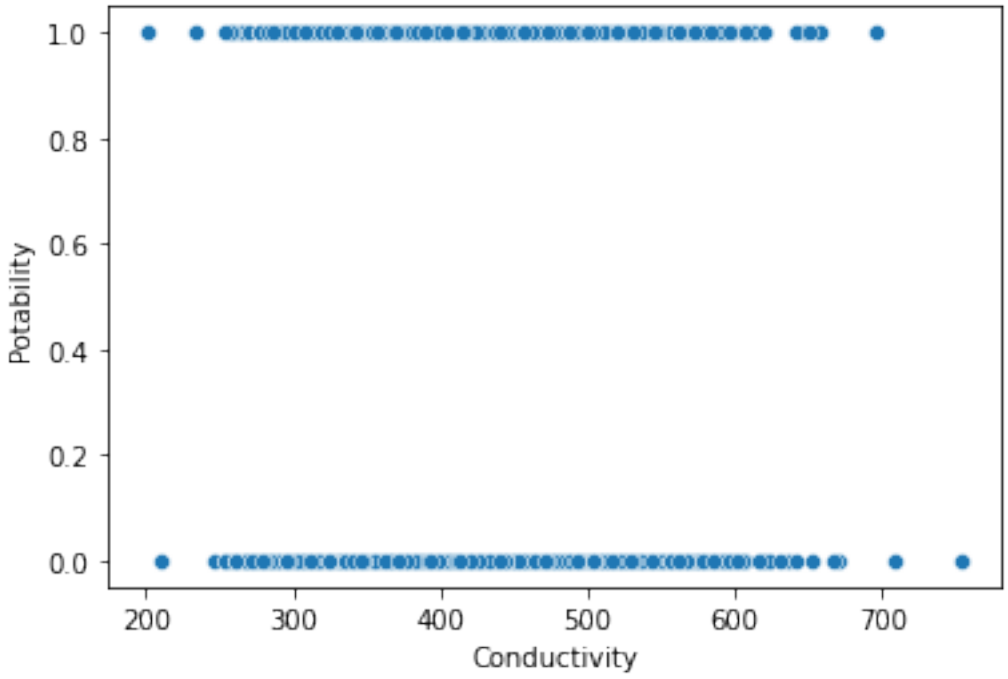

g. Korelasi OrganicCarbon dengan Potability

[ ]:
```
korelasi = round(df["OrganicCarbon"].corr(df["Potability"]),2)
print("Nilai korelasi:",korelasi)
if(korelasi > 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪OrganicCarbon dan Potability merupakan korelasi positif")
elif(korelasi < 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪OrganicCarbon dan Potability merupakan korelasi negatif")
else:
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪OrganicCarbon dan Potability tidak berkorelasi")

sns.scatterplot(data = df, x = "Solids", y = "Potability")
```

```
Nilai korelasi: -0.02
Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa OrganicCarbon
dan Potability merupakan korelasi negatif
```

[ ]:
```
<AxesSubplot:xlabel='Solids', ylabel='Potability'>
```

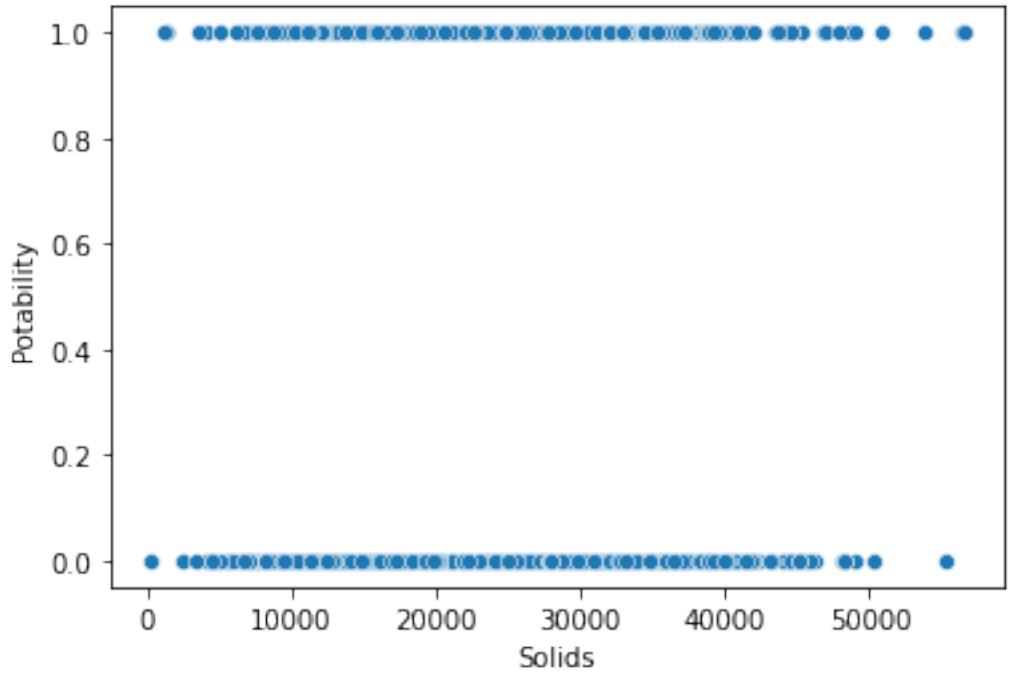

h. Korelasi Trihalomethanes dengan Potability

[ ]:
```
korelasi = round(df["Trihalomethanes"].corr(df["Potability"]),2)
print("Nilai korelasi:",korelasi)
if(korelasi > 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Trihalomethanes dan Potability merupakan korelasi positif")
elif(korelasi < 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Trihalomethanes dan Potability merupakan korelasi negatif")
else:
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Trihalomethanes dan Potability tidak berkorelasi")

sns.scatterplot(data = df, x = "Trihalomethanes", y = "Potability")
```

```
Nilai korelasi: 0.01
Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa
Trihalomethanes dan Potability merupakan korelasi positif
```

[ ]:
```
<AxesSubplot:xlabel='Trihalomethanes', ylabel='Potability'>
```

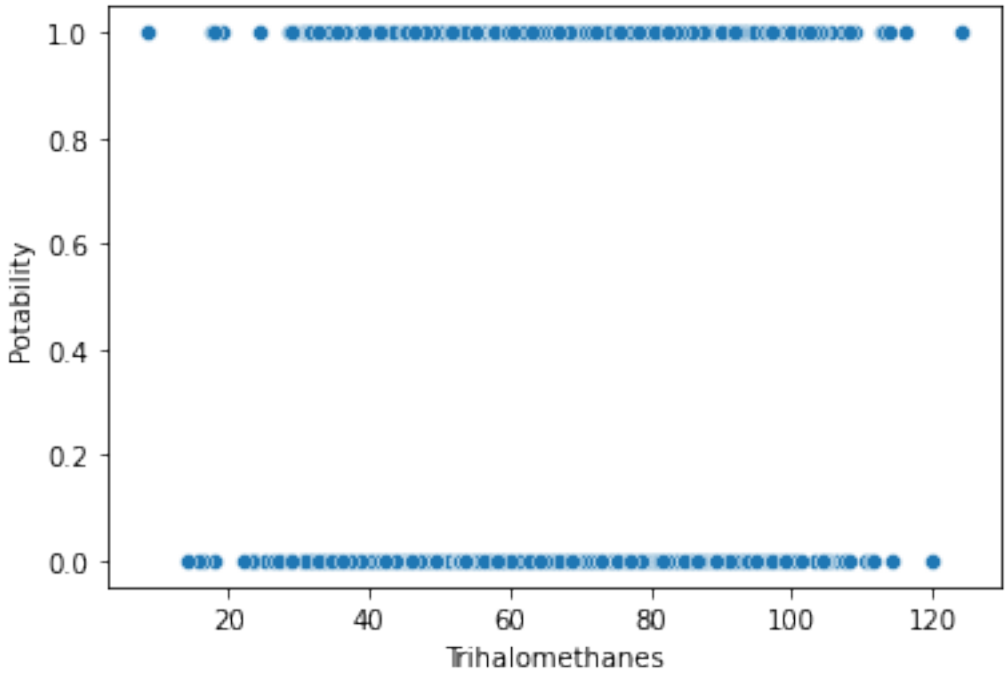

i. Korelasi Turbidity dengan Potability

[ ]:
```
korelasi = round(df["Turbidity"].corr(df["Potability"]),2)
print("Nilai korelasi:",korelasi)
if(korelasi > 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Turbidity dan Potability merupakan korelasi positif")
elif(korelasi < 0):
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Turbidity dan Potability merupakan korelasi negatif")
else:
    print("Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa␣
 ↪Turbidity dan Potability tidak berkorelasi")

sns.scatterplot(data = df, x = "Turbidity", y = "Potability")
```

```
Nilai korelasi: 0.02
Berdasarkan nilai korelasi yang didapatkan dapat disimpulkan bahwa Turbidity dan
Potability merupakan korelasi positif
```

[ ]:
```
<AxesSubplot:xlabel='Turbidity', ylabel='Potability'>
```

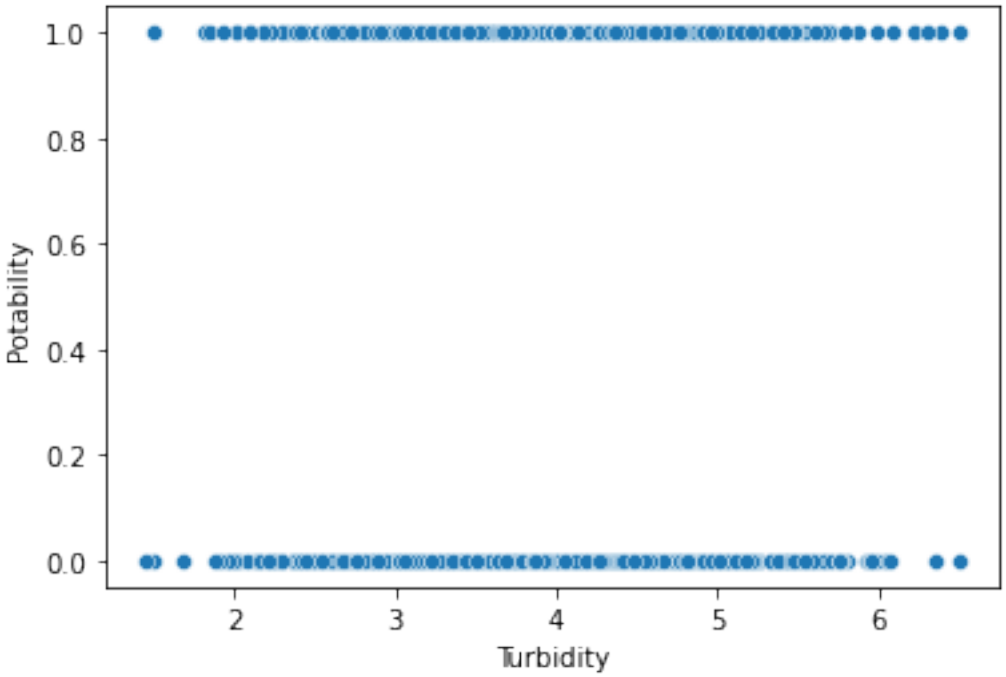
1.0
0.8
0.6
0.4
0.2
0.0
Potability
2
3
4
5
6
Turbidity